



第6章 生成式人工智能基础



湖北大学 计算机学院
王雷春



目录

6.1 概述


6.2 生成对抗网络


6.3 变分自编码器

6.4 自回归模型

6.5 Transformer

6.6 扩散模型







6.1 概述

6.1.1 背景与动机

6.1.2 什么是生成式AI

6.1.3 生成式AI分类






6.1.1 背景与动机

1. 背景


- ◆ (1)算法突破：生成对抗网络（GANs）、Transformer架构、扩散模型等的提出，让AI从“识别”跨越到“创造”。
- ◆ (2)数据爆炸：互联网提供的海量文本、图像等数据为更大模型和高质量数据生成奠定了基础。
- ◆ (3)算力提升：GPU（图形处理器）/TPU（张量处理器）等高性能芯片让训练超大模型成为可能。



6.1.1 背景与动机

2. 动机


- ◆ (1)追求创造能力：让AI不仅能分析现有内容（如识别猫、狗），还能创造全新内容（如画一只彩虹猫）。
- ◆ (2)解决数据难题：生成合成数据来训练模型，从而解决真实数据稀缺或涉及隐私的问题。
- ◆ (3)降低创作门槛：用自然语言与机器交互自动化生成文案、代码、设计稿等，提升学习和工作效率。
- ◆ (4)探索通用智能：验证AI是否真正理解世界，即能创造才能表明AI真正理解了数据背后的深层规律。



6.1.2 什么是生成式AI

定义


- ◆ 生成式AI是基于概率的人工智能模型，能够根据用户的提示（Prompt）或现有数据自动创建出新的、原创的、与训练数据相似但并非简单复制的内容。
- ◆ 传统AI（如分析型AI）主要是识别和判断，如识别一张图里是猫还是狗，判断一封邮件是否是垃圾邮件）。生成式AI致力于理解数据如何生成，通过学习海量数据背后的潜在规律与分布，进而能够从同一分布中采样并创造出全新、合理且富有创造性的内容，如文本、图形、图像、音频、视频和动画等。



6.1.2 什么是生成式AI

形象化比喻：一个画家的成长


- ◆ 生成式AI就像一位从“疯狂临摹”到“自由创作”的画家。
- ◆ 画家早期的“学徒生涯”看遍百万幅名画（海量数据学习），不仅记住每一笔，更悟出了色彩、光影与构图的内在规律（学习数据分布）。
- ◆ 出师后，画家不再复制任何一幅旧作，而是能根据一句描述（如“月光下的星空”）挥毫泼墨，画出世界上从未存在过的画作（生成新的作品）。



6.1.2 什么是生成式AI

特征


- ◆ (1)原创性：生成的内容不是简单复制粘贴，而是基于学习到的模式和规律进行创作。
- ◆ (2)概率性：即使输入相同的提示，每次生成的结果也可能不同，具有一定的随机性。
- ◆ (3)基于学习：生成能力来源于在大规模数据集上的训练时学习到的数据分布和关联。
- ◆ (4)条件性：生成过程通常受用户输入的指令或上下文条件引导。



6.1.3 生成式AI分类

1. 按技术架构分类


- ◆ (1)生成对抗网络 (GAN): 通过生成器与判别器的对抗博弈, 促使生成器学会以假乱真。代表模型包括StyleGAN、CycleGAN等。
- ◆ (2)变分自编码器 (VAE): 将数据压缩为低维隐变量, 再重建, 从而学习数据分布。代表模型包括 β -VAE、DALL-E (早期)等。
- ◆ (3)流模型 (Flow-based Models): 通过一系列可逆且平滑的变换 (称为“流”), 将一个简单的分布 (如高斯噪声) 精确地映射成复杂的数据分布。代表模型包括: Glow、RealNVP。由于扩散模型的兴起, 纯粹的流模型应用较少, 但其可逆变换思想对后续模型有重要影响。
- ◆ (4)扩散模型 (Diffusion): 学习从纯噪声逐步去噪恢复出原始数据的过程。代表模型包括Stable Diffusion、DALL-E 2、Sora等。



6.1.3 生成式AI分类

1. 按技术架构分类


- ◆ (5)自回归模型 (Autoregressive): 将生成视为序列预测, 根据已生成的部分, 逐元素预测下一个。代表模型包括GPT系列、PixelCNN等。
- ◆ 融合模型: 结合不同架构的优点, 突破单一模型的瓶颈。如, 扩散+Transformer, VAE+Transformer, 自回归+扩散, GAN+VAE



6.1.3 生成式AI分类

2. 按技术范式分类

- ◆ (1)传统生成模型。传统生成模型可进一步分为基于统计的传统生成模型和基于深度学习的早期生成模型。
 - ◆ A.基于统计的传统生成模型：利用概率图模型和统计方法对数据分布进行建模。代表模型包括隐马尔可夫模型（HMM）、朴素贝叶斯（Naive Bayes）、受限玻尔兹曼机（RBM）和概率图模型（PGM）等。
 - ◆ B.基于深度学习的早期生成模型：利用深度神经网络学习数据分布。代表模型包括生成对抗网络（GAN）、变分自编码器（VAE）和流模型（Flow-based Models）等。



6.1.3 生成式AI分类


2. 按技术范式分类

- ◆ (2)Transformer生成模型：利用自注意力机制和自回归方式处理序列数据。这类模型的优点是捕捉长距离依赖关系能力强、可扩展性极好（参数量越大能力越强）、在多模态任务（文本+图像+音频）中表现优异。代表模型包括GPT系列 (GPT-1/2/3/4)和BERT等。
- ◆ (3)扩散生成模型：通过逐步添加噪声（扩散过程）再学习逆向去噪过程来生成数据。这类模型优点是生成质量极高且细节丰富，训练稳定不易出现模式崩溃，多样性与保真度平衡好。代表模型包括DDPM、Stable Diffusion、DALL-E 2/3、Sora和Midjourney等。

6.1.3 生成式AI分类

3. 按生成内容模态划分

- ◆ (1)文本生成：最成熟的应用，如文章撰写、诗歌创作、代码编写、智能客服对话等。代表模型包括 GPT 系列、Claude等。
- ◆ (2)图像生成：根据文字描述或参考图生成全新的、逼真的图片。代表模型包括Midjourney、DALL-E 2等。
- ◆ (3)音频生成：包括文本转语音（TTS）、音乐创作等。代表模型包括 Jukebox、VALL-E等。
- ◆ (4)视频生成：根据文字描述生成短视频或进行视频编辑、风格迁移。代表模型包括Sora、Runway Gen-2等。
- ◆ (5)多模态生成：能同时处理并生成多种类型的内容。代表模型包括 GPT-4V、Gemini等。
- ◆ (6)3D内容生成：快速生成3D模型、游戏场景，加速游戏开发和工业设计。代表模型包括DreamFusion、GET3D等。



6.2 生成对抗网络


6.2.1 概述


6.2.2 模型结构

6.2.3 主要变体及改进

6.2.4 优点和缺点

6.2.5 应用场景及案例






6.2.1 概述

1. 什么是生成对抗网络

- ◆ 生成对抗网络 (Generative Adversarial Network, GAN) 是深度学习领域一种非常著名的生成框架, 属于无监督深度学习模型, 由Ian Goodfellow在2014年提出。
- ◆ GAN由两个相互博弈的神经网络 (生成器 (Generator) 和判别器 (Discriminator)) 构成, 通过对抗训练的方式, 使得生成器能够学习并捕捉到真实数据的内在分布, 从而生成与真实数据分布一致的全新样本。
 - ◆ (1)生成器: 负责 “伪造数据”, 即从随机噪声中生成假数据。
 - ◆ (2)判别器: 负责 “鉴定数据”, 即区分真实数据与伪造数据。
- ◆ 两者交替训练、相互对抗, 最终使生成器能够产生足以以假乱真的数据。




6.2.1 概述

2. 形象化比喻

伪造者 vs 鉴定师

- ◆ 生成器：制造假币的伪造者，其目标是造出以假乱真的假币。
- ◆ 判别器：银行柜台的鉴定师，其目标是识别所有假币。
- ◆ 工作过程：伪造者不断改进工艺（造更真的假币），鉴定师不断学习新特征（练就更毒的眼光），双方在互相对抗中共同进步。
- ◆ 最终结果：伪造者造出了连鉴定师也无法辨别的完美假币（生成器学会了生成以假乱真的数据）。





6.2.1 概述

3. 历史意义

- ◆ (1)提出了“对抗训练”这一全新框架：创造性地让两个神经网络（生成器与判别器）相互博弈、共同进化，无须复杂的马尔可夫链或变分下界，仅通过对抗就能生成高质量数据的思想，极具开创性。
- ◆ (2)极大提升了生成数据的真实感：GAN在图像生成领域取得了巨大成功，生成的图像比当时所有模型（如VAE）都更加清晰、锐利、逼真，开启了“深度伪造”和视觉内容创作的新纪元。
- ◆ (3)推动了生成式AI的爆发：GAN的思想深刻影响了后续无数工作，并催生了StyleGAN、CycleGAN等一系列变体，在图像编辑、风格迁移、数据增强等领域产生了重要应用。

6.2.2 模型结构






6.2.2 模型结构

(1)生成器 - “伪造者”


- ◆ 作用：学习真实数据的分布并从无到有地生成与真实数据高度相似的“假”数据。
- ◆ 输入：一个随机噪声向量，通常从高斯分布或均匀分布中采样得到。
- ◆ 输出：一个与真实数据维度相同的新数据样本，如图片、文本、音频等。
- ◆ 网络结构：通常是一个可微分的神经网络（如MLP、深度卷积神经网络等），通过学习将输入的随机噪声映射到目标数据空间。



6.2.2 模型结构

(2)判别器 - “鉴定者”

- ◆ 作用：一个二分类器，任务是区分输入是“真实”数据还是生成器产生的“虚假”数据。
- ◆ 输入：真实数据或生成器生成的假数据。
- ◆ 输出：一个 $[0,1]$ 区间的标量概率值，即被认为是“真实样本”的概率。
- ◆ 网络结构：通常是一个可用于分类的、可微分的神经网络（如MLP、CNN等）。




6.2.3 主要变体与改进

1. 条件GAN (Conditional Generative Adversarial Network, CGAN)

- ◆ 同时将CGAN的随机噪声向量和条件向量一起传递到生成网络中，以生成具有所需特征的样本，条件向量可以是数字或对象的标签，这样生成网络可以控制生成出来的图像具有特定的属性，如猫或狗的图像、戴眼镜的人的图像等。

2. 深度卷积GAN (Deep Convolutional GAN, DCGAN)

- ◆ DCGAN使用CNN替代传统GAN中的全连接网络，显著提高了生成图像的质量和稳定性。DCGAN关键特性包括：使用卷积层（而非全连接层）提高了图像生成的质量；引入了批量归一化 (Batch Normalization) 和 Leaky ReLU 激活函数，避免了模式崩塌 (Mode Collapse) 和梯度消失问题。




6.2.3 主要变体与改进

3. 循环GAN (Cycle GAN)

- ◆ CycleGAN是一种 无监督学习 方法，由Zhu等人在2017年提出。CycleGAN的主要创新在于能够在不需要成对训练数据的情况下，实现图像到图像的转换，如将夏天的照片转换为冬天的照片，将照片转换为油画风格，将白天的景象转换为夜晚等。

4. 风格GAN (Style GAN)

- ◆ StyleGAN是GAN的一个高级变体，由Karras等人在2018年提出。StyleGAN引入了风格嵌入和自适应实例归一化 (AdaIN) 技术，使生成图像的风格和内容可以独立控制。StyleGAN在高分辨率图像生成、图像编辑和风格迁移等任务中表现出色，生成的图像具有高度的逼真度和多样性。




6.2.3 主要变体与改进

5. Wasserstein GAN (Wasserstein GAN, WGAN)

- ◆ WGAN 提出了通过引入 Wasserstein 距离 来替代传统的 Kullback-Leibler 散度或 Jensen-Shannon 散度，以解决 GANs 中的训练不稳定性和模式崩塌问题。WGAN 的关键创新在于：使用 Wasserstein 距离来衡量生成分布和真实分布之间的距离，从而使训练更加稳定；引入权重剪切策略，从而避免梯度消失。

6. 渐进式 GAN (Progressive GAN, PGAN)

- ◆ PGAN生成图像时，通过从低分辨率开始逐渐增加分辨率，避免了生成器直接从高分辨率生成图像时的困难。PGAN 通过这种渐进式训练，生成的图像质量更高，能够处理更复杂的细节，尤其在人脸生成任务中表现出色。



6.2.3 主要变体与改进

5. Wasserstein GAN (Wasserstein GAN, WGAN)

- ◆ WGAN 提出了通过引入 Wasserstein 距离 来替代传统的 Kullback-Leibler 散度或 Jensen-Shannon 散度，以解决 GANs 中的训练不稳定性和模式崩塌问题。WGAN 的关键创新在于：使用 Wasserstein 距离来衡量生成分布和真实分布之间的距离，从而使训练更加稳定；引入权重剪切策略，从而避免梯度消失。

6. 渐进式 GAN (Progressive GAN, PGAN)

- ◆ PGAN生成图像时，通过从低分辨率开始逐渐增加分辨率，避免了生成器直接从高分辨率生成图像时的困难。PGAN 通过这种渐进式训练，生成的图像质量更高，能够处理更复杂的细节，尤其在人脸生成任务中表现出色。

6.2.4 优点和缺点

1. 优点

- ◆ (1)生成速度极快：这是GAN相比扩散模型和自回归模型最大的优势，它只需一次前向传播即可生成样本，无需迭代（不像扩散模型需要几十到上千步）。
- ◆ (2)图像质量高度逼真：在风格迁移、图像超分辨率、人脸生成等任务中，GAN生成的图像以其锐利、清晰、细节丰富而著称，能产生非常惊艳的视觉效果。
- ◆ (3)灵活的损失函数设计：判别器提供了一个可学习的损失函数，可以根据任务需求灵活设计，不必依赖固定的、可能不准确的数学度量（如像素级的MSE损失）。
- ◆ (4)潜在空间操作：GAN将高维数据（如图像）映射到低维的潜在空间（latent space），这个空间通常具有很好的向量算术特性，可以实现有特定要求的语义编辑。

6.2.4 优点和缺点

2. 缺点

- ◆ (1)训练极不稳定：训练GAN就像在玩一场永无止境的“猫鼠游戏”。生成器和判别器需要达到微妙的平衡（纳什均衡）。如果判别器太强，生成器学不到东西；如果生成器太强，判别器无法提供有效反馈。训练过程非常敏感，容易失败。
- ◆ (2)模式坍塌：这是GAN最经典的失败模式。生成器可能会发现一两个能“欺骗”判别器的“捷径”样本，然后就一直只生成这几个样本，失去了多样性。
- ◆ (3)缺乏评估指标：很难客观地评判一个GAN模型的好坏。。
- ◆ (4)难以生成离散数据：GAN主要通过梯度下降进行训练，而离散数据（如文本）的梯度难以从判别器反向传播到生成器。

6.2.5 应用场景及案例


1. 应用场景

(1) 图像生成与创作

- ◆ 生成高分辨率人脸/物体：生成不存在但极其逼真的人脸、卧室、猫等图像（如StyleGAN系列）。
- ◆ 艺术创作：生成具有特定风格的画作、设计服装或产品外观。

(2) 图像转换与编辑

- ◆ 图像到图像的翻译：将草图转为真实照片、卫星图转地图、白天转黑夜。
- ◆ 图像修复：补全破损照片或去除图像上的水印、遮挡物。
- ◆ 图像超分辨率：将模糊低清图像恢复为高清细节图。



6.2.5 应用场景及案例


1. 应用场景

(3) 数据增强与隐私保护

- ◆ 生成训练数据：为罕见病医疗影像、自动驾驶极端场景等生成合成数据，降低成本。
- ◆ 生成隐私保护数据：生成与真实数据分布相似但不含个人信息的合成数据，用于共享或训练。

(4) 视频与3D生成

- ◆ 视频预测：预测视频下一帧或生成动态短视频。
- ◆ 3D物体生成：从单张图片生成物体的多个视角或3D模型。



6.2.5 应用场景及案例

1. 应用场景

(5) 文本与语音应用

- ◆ 文本生成图像：根据文字描述生成相应图片（如DALL·E）。
- ◆ 语音增强：去除背景噪声或转换说话人音色。

(6) 科学发现

- ◆ 药物分子生成：设计具有特定性质的新分子结构。
- ◆ 天体物理模拟：生成模拟星系图像等。

6.2.5 应用场景及案例

2. 应用案例


【例6-1】构建一个生成对抗网络（GAN），让计算机学会生成逼真的手写数字图像（0-9）。

(1) 项目任务

- ◆ 设计一个基于生成对抗网络（GAN）的深度学习模型，该模型能够让计算机学习MNIST手写数字数据集的分布规律，从而能够从随机噪声中生成全新的、逼真的手写数字图像（类似MNIST数据集中的0-9）。

(2) 设计思路

- ◆ 生成器：从随机噪声生成假图像，输入为100维噪声向量，输出为 $28 \times 28 \times 1$ 的图像。
- ◆ 判别器：判断图像真假，输入为 $28 \times 28 \times 1$ 的图像，输出为标量概率（真/假）。



6.3.5 应用场景及案例

2. 应用案例

【例6-1】构建一个生成对抗网络（GAN），让计算机学会生成逼真的手写数字图像（0-9）。

(3)项目目录结构

- ◆ 参见项目

(4)运行



- ◆ 仅训练
- ◆ `python main.py --mode train`
- ◆ 仅生成（使用已训练的模型）
- ◆ `python main.py --mode generate`


6.3.5 应用场景及案例

2. 应用案例

【例6-1】构建一个生成对抗网络（GAN），让计算机学会生成逼真的手写数字图像（0-9）。

(5)结果






6.3.5 应用场景及案例

2. 应用案例

【例6-1】构建一个生成对抗网络（GAN），让计算机学会生成逼真的手写数字图像（0-9）。

(6)结果分析

- ◆ 初期（前5个epoch）：生成的图像完全是噪声
- ◆ 中期（10-20 epoch）：开始出现模糊的数字轮廓
- ◆ 后期（30-50 epoch）：生成清晰的数字，人眼可识别



6.3 变分自编码器


6.3.1 概述

6.3.2 模型结构

6.3.3 主要变体及改进

6.3.4 优点和缺点

6.3.5 应用场景及案例





6.3.1 概述

1. 什么是变分自编码器


- ◆ 变分自编码器 (Variational Autoencoder, 简称VAE) 是一种基于概率图模型和变分推断的深度生成模型, 由Diederik P. Kingma和Max Welling在2013年提出。
- ◆ 变分自编码器通过学习数据的潜在概率分布, 并从这个分布中采样解码, 从而生成与原始数据相似但全新的内容。
- ◆ VAE的核心思想是通过将输入编码为“概率分布范围”而非“固定点”, 并从中随机采样解码来生成连续、多样化新数据。传统自编码器(AE)把输入图片压缩成一个固定的代码(点), 但两个代码之间的中间点往往是乱码, 无法生成新图片。变分自编码器(VAE)把输入图片压缩成一个连续的、有范围的区域(分布)。在这个区域内随便选一个点解码, 都能生成一张合理、且与原图相似但不同的新图片。

6.3.1 概述

2. 形象化比喻

形象化比喻:素描师临摹名画


- ◆ 一位素描师学习临摹名画，希望学会创作出风格相似的新作品。
- ◆ 素描师采用的方法不是记录每个特征的精确数值，而是记录每个特征的“可能范围”。
- ◆ 编码器编码：观察分析过程。学习临摹《蒙娜丽莎》时，不记录“微笑弧度=5”，而是记录“微笑弧度在4到6之间，眼神方向在-1到+1之间，……”，把一幅画的各个特征变成了一个概率区间。
- ◆ KL散度：“职业素养”。强迫所有的记录都围绕在一个标准模板附近，保证“区间”在合理范围。
- ◆ 解码器解码：绘画创作过程。从记录的“微笑弧度区间”里随机选一个值（比如4.3），然后根据这个值画出一张类似的微笑。
- ◆ 如果想创作新画，只需要按照标准模板规定的区间生成即可。



6.3.1 概述


3. 历史意义

- ◆ (1)连接深度学习与贝叶斯推断：VAE首次将强大的深度网络与经典的变分推断框架结合，为后来的生成模型提供了标准范式。
- ◆ (2)解决传统自编码器的根本缺陷：VAE用“概率分布”替代“确定编码”，使得潜在空间连续且规则，解决了传统自编码器无法生成新样本的问题；提出的重参数化技巧也成为训练包含随机节点网络的关键技术。
- ◆ (3)影响深远：VAE与GAN、扩散模型并列为深度生成模型的“三大基石”。



6.3.2 模型结构

- ◆ (1)编码器：接收输入数据 x ，不直接输出一个编码向量 z ，而是输出一个分布（例如高斯分布的均值 μ 和方差 σ^2 ）。编码器的目标是学习从数据空间到潜在空间分布的映射。
- ◆ (2)潜在空间：一个低维的空间，其中每个点代表一个“隐变量” z 。关键点是，这个空间是连续且结构化的——相似的数据在潜在空间中会聚在一起。
- ◆ (3)解码器：从编码器输出的分布中随机采样一个 z 点，然后尝试将这个 z 重建回原始数据 x 。它的目标是学习从潜在空间分布到数据空间的映射。
- ◆ 这就像一个“概率”版的自动编码器，核心区别在于中间层编码的是一个分布而不是一个固定点。




6.3.3 主要变体与改进

1. β -VAE

- ◆ β -VAE是VAE的一个重要变体，在传统VAE的损失函数中引入了一个超参数 β ，核心目标是学习更解耦的表示。
- ◆ β -VAE通过增大KL散度项的权重 ($\beta > 1$)，在重建质量和表示解耦之间进行权衡，强制模型学习出更可解释、更独立的潜在因子。

◆ 2. VQ-VAE


- ◆ VQ-VAE (Vector Quantized Variational Autoencoder) 是一种将离散潜在表示与变分自编码器框架相结合的生成模型。VQ-VAE将连续潜在空间替换为可学习的离散码本，通过向量量化实现离散表示，再结合自回归先验生成清晰、高质量的数据。
- ◆ 通过使用离散的潜在空间，VQ-VAE在高质量生成（如语音、图像）中效果很好。



6.3.3 主要变体与改进

3. Conditional VAE


- ◆ Conditional VAE是传统VAE的一种条件扩展版本，通过引入条件变量来控制生成过程，使得模型能够有目的地生成特定类别的数据，而不是随机生成。
- ◆ Conditional VAE在传统VAE的编码器和解码器中同时加入条件信息 c ，使其能够根据指定的条件定向生成数据，同时保持生成多样性。



6.3.4 优点和缺点

1. 优点

- ◆ 有意义的潜在空间：VAE最大的优势,可以通过在潜在空间中平移 z 来平滑地改变生成图像的属性（如旋转角度、表情、物体形状等）。
- ◆ 训练稳定：相比GAN容易模式崩溃或训练不稳定，VAE训练过程可靠易收敛。
- ◆ 可推断性：不仅能生成新数据，还能推断给定数据的潜在表示 z ，便于分析数据的内在结构。
- ◆ 理论基础扎实：基于变分贝叶斯框架，有明确的概率解释和优化目标（ELBO）。



6.3.4 优点和缺点

2. 缺点


- ◆ 生成结果模糊：最突出的缺点。VAE倾向于生成平均化、边缘模糊的图像，缺乏 GAN 那样的锐利细节。
- ◆ 重建质量上限相对低：为了保持潜在空间的规整性，VAE会牺牲部分重建精度。
- ◆ 可能忽视细节：VAE可能只学会重建数据的整体轮廓，而丢失高频细节或小物体。

6.3.5 应用场景及案例

1. 应用场景

(1) 图像生成与编辑

- ◆ 生成新图像：生成手写数字、人脸、产品设计等多样化且合理的新样本（如生成不存在的人脸）。
- ◆ 图像编辑与属性操作：在潜在空间中进行向量加减来实现语义编辑。例如，“戴眼镜的人脸”的编码减去“不戴眼镜的人脸”的编码，再加上“你的脸”的编码，可得到“你的脸戴上眼镜”的效果。
- ◆ 图像插值：在两个真实图像之间进行平滑过渡（如从夏季风景逐渐变为冬季风景），生成连续变换的视频帧。



6.3.5 应用场景及案例

1. 应用场景

(2) 数据降维与可视化

- ◆ 非线性降维：将高维数据（如图像、基因数据）映射到2D或3D的潜在空间进行可视化，观察数据的聚类结构。由于VAE的潜在空间是连续且有规律的，可视化效果通常比PCA更清晰。
- ◆ 异常检测：利用“重建概率”。异常数据难以被VAE准确重建（重建误差大），可用于检测金融欺诈、网络入侵或工业设备故障。

6.3.5 应用场景及案例

1. 应用场景

(3) 序列数据处理与生成

- ◆ 文本生成：生成连贯的句子或段落（如对话回复、产品描述），并能控制文本的风格或主题。
- ◆ 音乐生成：学习音乐的潜在节奏与旋律结构，生成新的音乐片段。可通过调整潜在向量来改变情绪或乐器组合。
- ◆ 语音处理：语音转换（如将中性语音转换为情感语音）、语音增强（去除背景噪声）。

6.3.5 应用场景及案例

1. 应用场景

(4) 半监督学习与表征学习

- ◆ 半监督分类：在只有少量标注数据时，VAE能利用大量无标注数据学习有区分性的潜在特征，从而提升分类准确率。
- ◆ 解耦表征学习（如 β -VAE）：强制潜在变量相互独立，使得每个维度学习到独立的语义特征（如一个维度控制微笑程度，另一个维度控制性别）。有助于模型的可解释性。

(5) 跨模态生成

- ◆ 图像到图像的翻译：将草图转换为真实照片、黑白照片上色、卫星图转地图等。
- ◆ 文本到图像生成：根据文本描述生成相应图像（需结合其他模型如条件VAE）。

6.3.5 应用场景及案例

2. 应用案例

【例6-2】使用PyTorch-VAE中的普通VAE (VanillaVAE) 在Celeba数据集上训练模型，生成图片。

1. PyTorch-VAE下载

- ◆ PyTorch-VAE官方推荐从直接下载有困难时，可使用GitCode的镜像，将原来的github.com替换成 gitcode.com/gh_mirrors进行下载，命令如下：
- ◆ `git clone https://gitcode.com/gh_mirrors/py/PyTorch-VAE.git`
- ◆ 另一个下载网址及命令：
- ◆ `git clone https://github.com/AntixK/PyTorch-VAE.git`




6.3.5 应用场景及案例

2. 应用案例

【例6-2】使用PyTorch-VAE中的普通VAE（VanillaVAE）在Celeba数据集上训练模型，生成图片。

2. 数据集准备

- ◆ PyTorch-VAE默认使用CelebA人脸数据集进行训练。
- ◆ 下载数据集：从 CelebA 官方网站或其他可靠来源下载文件。
- ◆ 解压到指定位置：将解压后的文件夹（里面是所有图片）放到项目的 Data/celeba/目录下。
- ◆ 修改配置：打开configs文件夹里的.yaml配置文件（例如 vae.yaml），找到 data_params 部分，将data_path的值改成你存放数据的实际路径。




6.3.5 应用场景及案例

2. 应用案例

【例6-2】 使用PyTorch-VAE中的普通VAE (VanillaVAE) 在Celeba数据集上训练模型，生成图片。

3. 目录结构

◆ 参见项目



6.3.5 应用场景及案例

2. 应用案例

【例6-2】 使用PyTorch-VAE中的普通VAE (VanillaVAE) 在Celeba数据集上训练模型，生成图片。

4. 训练模型

- ◆ 训练模型命令如下：（在命令行切换到run.py所在的路径）
- ◆ `python run.py -c configs/vae.yaml`

6.3.5 应用场景及案例

2. 应用案例

【例6-2】使用PyTorch-VAE中的普通VAE（VanillaVAE）在Celeba数据集上训练模型，生成图片。

5. 生成图片

- ◆ 训练的是普通 VAE（VanillaVAE），不需要任何文本提示或条件控制，直接用随机噪声生成。
- ◆ 生成模型后，创建生成图片的文件generate.py，运行文件。
- ◆ 运行结果：

