


第4章 卷积神经网络及应用



湖北大学 计算机学院
王雷春



目 录


4.1 概述


4.2 CNN分类

4.3 基础CNN

4.4 常见CNN

4.5 CNN应用






4.4 经典CNN

4.4.1 经典CNN

4.4.2 使用方法



4.4.1 经典CNN

LeNet-5

1 什么是LeNet-5

- ◆ LeNet-5是Yann LeCun等人在1998年提出的经典卷积神经网络，主要用于解决手写数字和邮政编码的识别问题，用来识别类似MNIST数据集的图像。

LeNet-5的历史意义

- ◆ (1)开创了现代 CNN 标准范式。LeNet-5首次系统性地将卷积、池化、全连接结构组合成端到端的训练模型，奠定了现代卷积神经网络的基本设计框架。
- ◆ (2)证明了自动特征提取的可行性。打破了传统方法依赖手工设计特征的局限，证明网络可以自动从原始像素中学习到有效的层次化特征。

4.4.1 经典CNN

LeNet-5

1 什么是LeNet-5


- ◆ (3)推动了深度学习在工业界的应用。LeNet-5作为历史上第一个被成功大规模商用的 CNN，被广泛应用于美国的支票识别和手写邮编识别系统中，证明了深度学习在工业界的实际价值。
- ◆ LeNet-5结构简洁，参数较少，对算力要求低，在小任务上表现优异，适用于资源受限（CPU/嵌入式）或实时性要求高的场景，如手写/印刷字符识别、工业视觉检测、交通标志识别等。

4.4.1 经典CNN

LeNet-5

2 核心思想

- ◆ (1)局部感受野：每个神经元只连接输入图像的局部区域，捕捉边缘、角点等局部模式，避免全连接带来的参数爆炸。
- ◆ (2)权值共享：同一卷积核在整个图像上滑动时使用相同参数，检测同一种特征（如水平边缘），大幅减少参数量并保持平移不变性。
- ◆ (3)层次化特征提取：通过交替的卷积-池化层，自动学习从低级特征（边缘）到中级特征（局部形状）再到高级特征（整体数字）的层次表示。



4.4.1 经典CNN

LeNet-5

2 核心思想

- ◆ (4)空间下采样：池化层通过最大池化或平均池化降低特征图分辨率和减少计算量，同时增强对微小位移、形变的鲁棒性。
- ◆ (5)端到端学习：从原始像素直接输入到分类结果输出，所有参数通过反向传播自动学习，无需手工设计特征提取器。


4.4.1 经典CNN

LeNet-5

3 网络架构

- ◆ (1)输入层: 32×32 灰度图
- ◆ (2)C1卷积层: 6 个 5×5 卷积核 $\rightarrow$ 输出 $28 \times 28 \times 6$
- ◆ (3)S2池化层: 2×2 平均池化 (步长2) $\rightarrow 14 \times 14 \times 6$
- ◆ (4)C3卷积层: 16 个 5×5 卷积核 $\rightarrow 10 \times 10 \times 16$
- ◆ (5)S4池化层: 2×2 平均池化 (步长2) $\rightarrow 5 \times 5 \times 16$
- ◆ (6)C5卷积层: 120 个 5×5 卷积核 $\rightarrow 1 \times 1 \times 120$ (本质为全连接)
- ◆ (7)F6全连接层: 84 个神经元
- ◆ (8)输出层: 10 个神经元






4.4.1 经典CNN

LeNet-5

4 应用场景

- ◆ (1)手写数字/字符识别：如最初的支票、邮政编码自动识别等。
- ◆ (2)安防与自动驾驶：如车牌识别、交通标志识别等。
- ◆ (3)工业产品分选：如快速识别碎米、垳白米或对大豆品种进行分类等。
- ◆ (4)医疗影像辅助分析：用于脑出血分类、自闭症筛查等基础影像识别。



4.4.1 经典CNN

AlexNet

1 什么是AlexNet

- ◆ AlexNet是一种深度卷积神经网络架构，由Alex Krizhevsky、Ilya Sutskever和Geoffrey Hinton于2012年提出。
- ◆ AlexNet首次在大规模图像识别中系统性地引入ReLU激活函数、Dropout正则化、数据增强和GPU并行训练，在2012年ImageNet图像分类竞赛中以15.3%的Top-5错误率一举夺魁。
- ◆ 被誉为深度学习计算机视觉领域的“开山之作”，结构设计深刻影响了后续卷积神经网络的发展。


4.4.1 经典CNN

AlexNet

1 什么是AlexNet

历史意义：

- ◆ (1)开启深度学习时代：AlexNet的胜利证明了深层神经网络在视觉任务上的统治力；
- ◆ (2)GPU通用计算里程碑：首次在大规模AI任务中展示GPU的并行计算优势，直接推动NVIDIA CUDA生态发展；
- ◆ (3)技术范式的确立：ReLU、Dropout、数据增强等技术成为此后所有CNN的标准配置；
- ◆ (4)人才孵化：团队成员Ilya Sutskever后来成为OpenAI联合创始人及首席科学家。




4.4.1 经典CNN

AlexNet

2 核心思想

- ◆ (1)采用 ReLU 激活函数：替代传统的 Sigmoid/Tanh，有效缓解梯度消失问题，加速网络收敛。
- ◆ (2)使用 Dropout 正则化：在全连接层随机丢弃部分神经元，防止过拟合，提升泛化能力。
- ◆ (3)数据增强：通过随机裁剪、水平翻转、颜色抖动等方式扩充训练样本，降低过拟合风险。
- ◆ (4)重叠池化：采用步长小于池化窗口尺寸的重叠最大池化，保留更多信息，提升特征表达。



4.4.1 经典CNN

AlexNet

2 核心思想

- ◆ (5)局部响应归一化 (LRN)：对局部神经元活动进行竞争性归一化，增强泛化能力（后续被批归一化取代）。
- ◆ (6)GPU 并行训练：利用两块 GPU 将网络拆分训练，解决了当时显存瓶颈，大幅提升训练效率。
- ◆ (7)深层结构设计：构建了 8 层可学习网络（5 个卷积层 + 3 个全连接层），证明深度可以带来更强的特征学习能力。

4.4.1 经典CNN

AlexNet

3 模型架构

- ◆ 共8层：5层卷积 + 3层全连接，总参数量约6000万




4.4.1 经典CNN

AlexNet

4 应用场景

- ◆ (1)图像分类与识别。例如，在ImageNet竞赛等大规模、多类别的图像识别任务中，使用AlexNet从1000个类别中准确识别出具体的物体（如不同品种的狗或猫等）。
- ◆ (2)目标检测。AlexNet作为区域卷积神经网络系列目标检测模型的骨干网络，如自动驾驶中的车辆、行人检测等。
- ◆ (3)迁移学习与特征提取。AlexNet作为“特征提取器”应用于小数据集任务，如在医疗影像分析中利用其在ImageNet上预训练的权重对X光片的肺炎分类。
- ◆ (4)视频分析与行为识别。例如，在视频流处理中，AlexNet被用于提取每一帧的图像特征，识别监控视频中的异常行为或体育视频中的人体动作等。



4.4.1 经典CNN

VGGNet

1 什么是VGGNet

- ◆ VGGNet是牛津大学视觉几何组（Visual Geometry Group）在2014年提出的卷积神经网络，以结构规整、深度显著增加为主要特点。在ILSVRC 2014比赛中，VGGNet获得了分类项目亚军、定位项目冠军。

历史意义

- ◆ (1)证明了“网络深度”是提升性能的关键。VGGNet把网络层数从11层增加到19层，图像识别准确率持续提升，推动了后续网络向更深方向（如ResNet的152层）发展。

4.4.1 经典CNN

VGGNet

1 什么是VGGNet

- ◆ (2)确立了小卷积核堆叠的经典设计范式。提出用多个 3×3 小卷积核替代单个大卷积核，在保持相同感受野的前提下减少参数量并增加非线性表达能力，成为此后CNN架构的黄金标准。
- ◆ (3)成为迁移学习的通用骨干网络。VGGNet由于结构规整、层次清晰，其预训练模型成为计算机视觉任务最常用的特征提取器，在目标检测、图像分割等众多任务中替换卷积层部分。

4.4.1 经典CNN

VGGNet

2 核心思想


- ◆ (1)小卷积核堆叠：使用多个 3×3 卷积层串联，获得与大卷积核（如 5×5 或 7×7 ）相同的感受野，同时减少参数量并增加非线性。
- ◆ (2)池化层：统一采用 2×2 最大池化（步长2），使特征图尺寸减半。
- ◆ (3)统一网络结构：所有卷积层使用相同尺寸的 3×3 核和步长 1、填充 1，池化层统一为 2×2 最大池化，结构规整、易于复现。
- ◆ (4)深度取胜：通过增加层数（16 ~ 19 层）显著提升图像分类精度。


4.4.1 经典CNN

VGGNet

3 模型架构

- ◆ VGGNet共有6个配置版本（A~E），常用的是VGG16和VGG19VGGNet。
- ◆ VGG16包含13个卷积层和3个全连接层，分为5个Block，如下图所示。





4.4.1 经典CNN

VGGNet

4 应用场景

- ◆ VGGNet通常用于任务需要较深网络结构且对特征提取能力要求较高的场景下，作为更复杂视觉系统的特征提取器
- ◆ 作为R-CNN系列、SSD、YOLO等检测框架的骨干网络（Backbone）
- ◆ 用于FCN、U-Net 等分割模型的编码器部分提取多尺度特征等。

4.4.1 经典CNN

ResNet

1 什么是ResNet

- ◆ ResNet (Residual Neural Network, 残差网络) 是2015年由微软亚洲研究院的何恺明等人提出的深度卷积神经网络。它在ILSVRC 2015竞赛中一举夺得图像分类、目标检测、图像分割三项冠军, Top-5错误率低至3.57%, 超越了人类水平 (约5%) 。
- ◆ ResNet通过引入“跳跃连接”或“恒等捷径”, 让网络学习输入与输出之间的“残差映射”, 而非直接学习完整的底层映射。ResNet的这种设计使得网络可以轻松地实现恒等映射, 有效缓解了梯度消失和网络退化问题, 从而能够训练上百甚至上千层的超深网络。

4.4.1 经典CNN

ResNet

1 什么是ResNet

主要意义

- ◆ (1)开创了“超深网络”训练范式。通过残差连接彻底解决了梯度消失和网络退化问题，首次证明上百层（乃至上千层）网络可以有效训练，打破了此前“网络越深越难训练”的认知瓶颈。
- ◆ (2)成为计算机视觉的通用骨干。ResNet及其预训练模型凭借良好的特征提取能力迅速取代VGG等架构成为图像分类、目标检测、语义分割等几乎所有视觉任务的基准骨干网络和后继模型比较对象。
- ◆ (3)影响超越视觉领域。残差连接的设计思想被Transformer等架构广泛借鉴，成为现代深度学习核心组件之一，极大推动了NLP等其它领域的发展。

4.4.1 经典CNN

ResNet


2 核心思想


- ◆ ResNet的核心思想是引入“残差学习”与“跳跃连接”，以解决极深网络中的梯度消失和网络退化（即层数增加但训练误差不降反升）问题，使得网络深度可以轻易达到上百甚至上千层。
- ◆ (1)残差映射替代直接映射：不再让网络直接拟合期望的底层映射 $H(x)$ ，而是让网络拟合残差 $F(x)=H(x)-x$ ，最终输出为 $H(x)=F(x)+x$ 。
- ◆ (2)跳跃连接：通过一个恒等映射（identity shortcut）将输入直接加到输出上，使梯度可以绕过非线性层直接反向传播。

4.4.1 经典CNN

ResNet

3 模型架构





4.4.1 经典CNN

ResNet

4 应用场景


- ◆ (1)图像分类。作为ImageNet等大规模识别任务的基准模型，ResNet通过上百层的深度有效提取从边缘到语义的层级特征，被广泛用于电商商品分类、菜品识别等场景。
- ◆ (2)目标检测。作为Faster R-CNN、YOLO等检测模型的骨干网络，提取高质量的候选区域特征；同时作为Mask R-CNN编码器，实现像素级的实例分割，广泛应用于自动驾驶（车辆/行人检测）、安防监控和工业质检。

4.4.1 经典CNN

ResNet

4 应用场景


- ◆ (3)人脸识别。通过ResNet提取512维或更高维度的深度特征嵌入，结合ArcFace等损失函数实现高效的人脸比对与检索，应用于人脸门禁、支付验证及安防布控。
- ◆ (4)迁移学习基座。作为通用的预训练模型，下游任务可以去掉其分类层并用小数据微调，快速适配医学影像诊断（如CT、X光片分类）、遥感图像分析和视频行为识别等场景。




4.5 CNN应用

4.5.1 应用场景

4.5.2 应用案例






4.5.1 应用场景

1 计算机视觉

(1) 图像分类

- ◆ 智能手机相册管理：Google Photos、苹果相册自动将照片分为 “人物” “动物” “风景” “文档” 等。
- ◆ 电商商品类目预测：淘宝、Amazon拍照识别商品，自动推荐类目。
- ◆ 医疗影像初步诊断：对X光胸片判断 “正常/肺炎”，对眼底图像判断 “糖尿病视网膜病变”。
- ◆ 卫星图像地物分类：对卫星图块分类为 “森林” “农田” “水域” “城市”。
- ◆ 内容安全审核：检测用户上传图片是否包含 “色情” “暴力” “政治敏感” 等。




4.5.1 应用场景

1 计算机视觉

(1)图像分类

- ◆ 检测用户上传图片是否包含“色情”“暴力”“政治敏感”等。
- ◆ 工业外观检查：对产品整体图像分类“合格/瑕疵”，如印刷电路板、塑料件。
- ◆ 植物病虫害识别：农户拍摄叶片，判断病害种类及严重程度。
- ◆ 文档自动分类：扫描仪识别证件类型（身份证、护照、驾照），自动归档。




4.5.1 应用场景

1 计算机视觉

(2)目标检测

- ◆ 自动驾驶与辅助驾驶：自动检测车辆周围的其它车辆、行人、交通标志和道路线等，辅助车辆的驾驶。
- ◆ 安防与智能监控：对监控区域进行异常行为、人流/车流统计、遗留物/物品和烟火检测等进行检测，并确定其空间范围，帮助工作人员自动监控和辅助决策。
- ◆ 医学影像辅助诊断：对CT或X光图像中对疑似病灶对检测和定位，辅助医生排查各种疾病。
- ◆ 工业质检与自动化：包括但不限于对产品表面缺陷检测，零件装配完整性检查，包装检测等，帮助工厂对产品质量进行控制。




4.5.1 应用场景

1 计算机视觉

(2)目标检测

- ◆ 船舶检测：在港口卫星图像中定位船舶，用于渔业监管、港口管理。
。
- ◆ 飞机检测：在机场图像中框出停机坪上的飞机，辅助调度。
- ◆ 建筑物/车辆检测：用于城市规划、车流量分析、军事侦察。
- ◆ 人脸检测：自动框出手机相册中的人脸，用于美颜、对焦、人物分类。。




4.5.1 应用场景

1 计算机视觉

(3)图像分割

- ◆ 医疗影像分析：辅助医生在CT/MRI影像中自动分割肿瘤、器官，完成眼底血管分析，提升诊断精准度。
- ◆ 自动驾驶感知：精确识别道路、车辆、行人及交通标识等区域，为路径规划提供基础。
- ◆ 遥感与地理空间：分析卫星/无人机图像，进行土地利用分类（如森林、农田、水体），帮助城市规划与资源管理。
- ◆ 工业与安防：实现工业产品表面微小缺陷的像素级检测；在安防视频中精准定位、追踪可疑目标。
- ◆ 农业与零售：识别农作物病虫害区域；在稻田中区分水稻与杂草以进行精准喷洒。




4.5.1 应用场景

2 其它领域

(1)自然语言处理 (NLP)

- ◆ 文本分类与情感分析：如通过分类“喜悦”、“愤怒”等情绪分析文本情感、在社交媒体垃圾信息检测中识别协同造假行为、通过智能客服系统自动识别用户意图进行路由，以及在电子取证场景中通过主题建模辅助内容审查。
- ◆ 机器翻译：作为编码器-解码器架构的一部分，先提取源语言特征，再由解码器翻译，性能也可用于识别跨多语言的评论情感。
- ◆ 命名实体识别 (NER)：用于从文本中识别出特定意义的实体（如人名、地名、时间等）。



4.5.1 应用场景


2 其它领域

(2)语音与音频处理。将音频信号转为声谱图，CNN便能将其作为图像处理，从而实现高效的时频特征提取，在嘈杂环境中稳定识别。

- ◆ 语音识别与唤醒：在智能音箱和视频会议中增强语音质量，结合视觉信息（口型）实现人声分离，并通过音频标签/事件检测触发警报或警报。

(3)推荐系统与行为预测。学习用户行为序列，类比“序列图像”捕捉历史行为中的局部模式偏好，发现产品或新闻之间的关联。

- ◆ 序列推荐：分析浏览记录预测用户下一步互动（如电影推荐），并捕捉时空偏好进行个性化推送（如推荐下一家餐馆）。




4.5.1 应用场景

2 其它领域

(4)药物发现与生物信息学。将分子结构（2D化学式或3D点云）视为“图像”输入，自动抓取决定分子性质的关键团基。

- ◆ 分子性质预测：预测药物毒副作用以辅助筛选。
- ◆ 药物-靶标相互作用 (DTI) 预测：寻找能与致病蛋白结合的药物分子，具备预测新型药物分子结构的能力。



4.5.2 应用案例

2 图像分类案例

【例4-7】 使用预训练模型ResNet-18对CIFAR-10图像进行分类。

1. 任务概述

- ◆ 本案例通过ResNet-18在ImageNet大规模数据集上学到的通用视觉特征，通过迁移学习对CIFAR-10数据集的进行图像分类，从而减少训练时间和数据需求。

4.5.2 应用案例


2 图像分类案例

【例4-7】 使用预训练模型ResNet-18对CIFAR-10图像进行分类。

1. 任务概述

具体任务

- ◆ (1)实现高效迁移：验证预训练模型在不同数据集上的特征迁移能力，通过微调少量网络层来适应新任务。
- ◆ (2)解决小数据挑战：针对CIFAR-10数据集规模有限（仅5万张训练图像，32x32像素）且图像尺寸小的特点，探索如何调整ResNet-18的输入层和卷积核以保持有效特征提取。
- ◆ (3)资源优化实践：利用ResNet-18参数量相对较小（约1100万）的优势，在有限的计算资源（如单GPU或CPU）上快速完成训练，演示深度学习的实际落地流程。



4.5.2 应用案例

2 图像分类案例

2. 环境配置

- ◆ (1)硬件配置：CPU、GPU（加速计算过程）。
- ◆ (2)软件和工具包：Python、torch、numpy、scikit-learn、matplotlib和torchvision等。
- ◆ 软件和工具包的详细要求见项目的“依赖清单” requirements.txt。
- ◆ 安装命令如下：
- ◆ `pip install -r requirements.txt`

4.5.2 应用案例

2 图像分类案例

3 ResNet-18简介

- ◆ ResNet-18的预训练模型是指在ImageNet大规模图像数据集（超过100万张图像，1000个类别）上预先训练好的网络权重。使用预训练模型可以极大加速开发流程，无需从头训练即可获得高性能的特征提取能力。
- ◆ (1)核心规格与性能
- ◆ 参数量：11.69M（约1169万）
- ◆ 文件大小：44.7 MB
- ◆ 输入尺寸：3×224×224（RGB图像）
- ◆ Top-1 准确率：69.76%
- ◆ Top-5 准确率：89.08%


4.5.2 应用案例

2 图像分类案例

3 ResNet-18简介

(2)使用方法 (PyTorch)

- ◆ `import torch`
- ◆ `import torchvision.models as models`
- ◆ # 方法1: 使用pretrained参数 (旧版语法)
- ◆ `model = models.resnet18(pretrained=True)`
- ◆ # 方法2: 使用weights参数 (推荐, 新版语法)
- ◆ `model =`
`models.resnet18(weights=models.ResNet18_Weights.IMAGENET1K_V1)`
- ◆ # 方法3: 使用DEFAULT
- ◆ `model = models.resnet18(weights='DEFAULT')`



4.5.2 应用案例

2 图像分类案例

3 ResNet-18简介

(2)使用方法 (PyTorch)

- ◆ # 设置为评估模式 (推理时必须)
- ◆ `model.eval()`

4.5.2 应用案例

2 图像分类案例

4 数据准备与预处理


- ◆ 下载CIFAR-10数据集（包括训练集和测试集）到指定目标下并加载。
- ◆ `transform_train = transforms.Compose([`
- ◆ `transforms.Resize(224),` # 放大到224x224
- ◆ `transforms.RandomHorizontalFlip(),` # 随机水平翻转
- ◆ `transforms.RandomCrop(224, padding=4),` # 随机裁剪
- ◆ `transforms.ToTensor(),`
- ◆ `transforms.Normalize(mean=[0.485, 0.456, 0.406],`
- ◆ `std=[0.229, 0.224, 0.225])`
- ◆ `])`

4.5.2 应用案例

2 图像分类案例

4 数据准备与预处理

- ◆ # 加载CIFAR-10数据集
- ◆ `train_dataset=datasets.CIFAR10(root='./data',train=True,download=True,transform=transform_train)`
- ◆ # 创建DataLoader
- ◆ `train_loader = DataLoader(train_dataset, batch_size=64, shuffle=True, num_workers=2)`




4.5.2 应用案例

2 图像分类案例

5 构建预训练模型（迁移学习）

- ◆ 冻结骨干网络：将 ResNet 的 parameters 全部冻结（requires_grad=False），这样在训练时只有新添加的层会更新参数，能极大地节省训练时间和资源。
- ◆ 替换全连接层：原模型的最后一层 (model.fc) 是为1000个类别设计的。将其替换为一个新的、有10个输出节点的线性层，并确保这个新层的 requires_grad 为 True加载预训练模型并修改输出层。
- ◆ 定义损失函数和优化器。损失函数采用交叉熵损失函数，优化器采用Adam（初始学习率设置为0.001），学习率调度器采用StepLR。



4.5.2 应用案例

2 图像分类案例

6 训练函数

- ◆ 损失函数接收模型 (model)、训练集 (train_loader)、损失函数 (criterion)、优化器 (optimizer)、学习率调度器 (scheduler) 和训练轮数等，对模型进行训练。

7 评估函数


- ◆ 损失函数接收模型 (model)、测试集 (test_loader) 对模型进行评估。

8 单张图像预测函数

- ◆ 对单张图像进行预测。显示测试的图像和各类别预测概率。

9 主程序

- ◆ 调用训练函数、评估函数、预测函数等对模型进行训练、测试和显示预测结果。



4.5.2 应用案例

2 图像分类案例

6 运行结果

- ◆ 训练完成!
- ◆ 模型已保存为 resnet18_cifar10.pth
- ◆ === 评估模型 ===
- ◆ 测试集准确率: 81.21%
- ◆ === 单张图像预测演示 ===
- ◆ 真实类别: cat
- ◆ 预测类别: cat
- ◆ 预测概率: 0.8457

4.5.2 应用案例

2 图像分类案例

True: cat
Pred: cat




True: ship
Pred: ship



True: ship
Pred: ship



True: airplane
Pred: airplane




True: frog
Pred: frog




True: frog
Pred: frog




True: automobile
Pred: automobile



True: frog
Pred: frog



True: cat
Pred: cat



True: automobile
Pred: automobile




4.5.2 应用案例


2 图像分类案例

预测类别: cat



各类别预测概率





4.5.2 应用案例

3 目标检测案例

1 目标检测简介


- ◆ 目标检测是计算机视觉领域的核心任务之一，它不仅要识别出图像或视频中有什么物体，还要精确地框出它们的位置。
- ◆ 简单来说，它需要回答两个核心问题：一是“图像/视频里有什么？”（物体分类），二是“这些物体在哪里？”（物体定位）。与仅给整张图片打标签的图像分类或进行像素级分割的图像分割相比，目标检测结合了“是什么”与“在哪儿”的双重任务，因此在自动驾驶、安防监控、医疗影像分析等需要精准理解场景的应用中尤为关键。

4.5.2 应用案例

3 目标检测案例

2 YOLO 核心思想

- ◆ YOLO(You Only Look Once)将目标检测视为回归问题，一次前向传播同时预测边界框和类别概率。包括以下四个方面的内容：
 - ◆ 将输入图像划分为 $S \times S$ 网格。
 - ◆ 每个网格预测 B 个边界框 ($B=2$) 和 C 个类别概率 (VOC 中 $C=20$)。
 - ◆ 每个边界框包含 $(x, y, w, h, \text{confidence})$ 5 个值。
 - ◆ 最终输出张量尺寸: $S \times S \times (B*5 + C) = 7 \times 7 \times 30$ 。




4.5.2 应用案例

3 目标检测案例

3 PASCAL VOC简介

- ◆ PASCAL VOC全称Pattern Analysis, Statistical modelling and ComputAtional Learning - Visual Object Classes，由牛津大学、ETH Zurich等顶尖机构的研究者发起，可以看作是目标检测领域的“启蒙教科书”。在它诞生之前，该领域的研究者们各自为战，模型之间难以进行公平比较。PASCAL VOC通过提供一套标准化的高质量数据集、明确的评估体系和年度竞赛，为现代目标检测技术的发展奠定了基础，并确立了沿用至今的核心评估标准。
- ◆ PASCAL VOC主要用于目标检测、图像分类、语义分割、动作识别等，其中目标检测最为著名。



4.5.2 应用案例

3 目标检测案例

3 PASCAL VOC简介


- ◆ 在实际使用中，PASCAL VOC主要指代两个最成熟的版本：VOC 2007 和 VOC 2012。
- ◆ VOC 2007：图片总数9,963张，标注物体数24,640个，提供官方独立的测试集，作为测试集，评估模型的最终性能。
- ◆ VOC 2012：图片总数11,530张，标注物体数27,450个，作为VOC 2007的升级版，数据更丰富，作为训练集，提供更多多样化的数据来训练模型。

4.5.2 应用案例

3 目标检测案例

3 PASCAL VOC简介

- ◆ VOCdevkit/
 - ◆ └─ VOC2007 (或 VOC2012)/
 - ◆ └─ JPEGImages/
 - ◆ └─ Annotations/
 - ◆ └─ ImageSets/
 - ◆ └─ Main/
 - ◆ └─ SegmentationClass/
 - ◆ └─ SegmentationObject/
- # 数据集根目录
- # 特定版本目录
- # 所有原始图片 (jpg格式)
- # 与图片对应的XML标注文件
- # 不同任务的数据集划分 (txt)
- # 目标检测任务的文件划分
- # 语义分割的像素级标注图
- # 实例分割的像素级标注图



4.5.2 应用案例

3 目标检测案例

3 PASCAL VOC简介

- ◆ PASCAL VOC定义了20个日常物体类别，可分为四大类，简洁且覆盖了多样化的日常场景：
 - ◆ 交通工具(Vehicle): aeroplane, bicycle, boat, bus, car, motorbike, train
 - ◆ 家居物品(Household): bottle, chair, dining table, potted plant, sofa, tv/monitor
 - ◆ 动物(Animal): bird, cat, cow, dog, horse, sheep
 - ◆ 人物(Person): person

4.5.2 应用案例

3 目标检测案例

【例4-8】 使用预训练模型YoLoV5对VOC 数据集进行目标检测。

- ◆ (1)任务概述
- ◆ 本案例的任务是通过使用训练好的模型yolov5在VCO2007数据集上训练一个高效、准确的目标识别模型。具体如下：
- ◆ (1)算法验证：检验YOLOv5在20类通用物体（如人、车、狗等）上的目标检测性能。
- ◆ (2)流程实践：熟悉目标检测从环境配置、数据准备、格式转换、数据集划分到模型训练、模型评估与推理实现等的整个流程。
- ◆ (3)模型产出：得到一个能够实时、精准识别各类目标的专用模型权重，为后续的部署或迁移学习提供基础。

4.5.2 应用案例

3 目标检测案例

【例4-8】 使用预训练模型YOLOV5对VOC 数据集进行目标检测。


- ◆ 其中，YOLOv5是一个基于PyTorch实现的主流目标检测算法。它将目标检测视为一个回归问题，通过单个神经网络直接从图像中预测物体的类别和位置，速度快、精度高且部署友好。



4.5.2 应用案例

4 图像分割案例


- ◆ 图像分割是计算机视觉中“像素级”的任务，要求模型精确地理解图像中的每一个点，实现像素级的分类，精确地勾勒出图像中每个物体的完整轮廓。
- ◆ 图像分割包括三大核心子任务：
 - ◆ 语义分割：将图像中所有像素分类，关注“是什么”，但不区分个体。例如，图像中所有“汽车”像素标为红色，但分不清是车A还是车B。代表模型有FCN、U-Net、DeepLab等。
 - ◆ 实例分割：在检测物体的同时，区分同类不同个体，关注“是哪一个”。例如，给每辆汽车标上不同颜色，区分车A、车B和车C。代表模型有Mask R-CNN、YOLACT等。



4.5.2 应用案例

4 图像分割案例

- ◆ 全景分割：融合了语义和实例分割的统一格式，对“物体”（可数）进行实例分割，对“背景”（如天空、草地）进行语义分割。例如，精确区分三辆车和一个人，并将道路、天空等背景归类。代表模型有Panoptic FPN、DetectoRS等。




4.5.2 应用案例

4 图像分割案例

【4-9】 使用CNN预训练模型在PASCAL VOC 2012数据集上进行语义分割。

- ◆ 1. 概述
- ◆ 本案例实现了一个基于DeepLabV3+架构和MobileNetV3-Large骨干网络的轻量级语义分割模型，专门用于PASCAL VOC 2012数据集的图像分割任务。该模型在保持较高分割精度的同时，具有参数量小、推理速度快的特点，适合在资源受限的边缘设备上部署。具体如下：
- ◆ (1)精准的像素级分类：实现对输入图像中每一个像素点的类别预测,能够准确区分PASCAL VOC 2012数据集中的20种前景物体类别(如人、车、狗等)以及背景类别。



4.5.2 应用案例

4 图像分割案例

【4-9】 使用CNN预训练模型在PASCAL VOC 2012数据集上进行语义分割。

- ◆ (3)迁移学习实践：利用在ImageNet上预训练的MobileNetV3权重作为模型编码器的初始化,通过“冻结-解冻”等策略进行微调,验证迁移学习在提升训练效率与分割性能方面的有效性。
- ◆ (4)模型产出：产出一个能够实时、精准地对图像进行语义分割的专用模型权重文件，为后续的边缘计算场景或进一步研究提供基础。