



第2章 机器学习基础





湖北大学 计算机学院
王雷春



目 录

- 2.1 机器学习概述
- 2.2 数据预处理和特征工程
- 2.3 机器学习分类
- 2.4 常用监督学习算法
- 2.5 常用无监督学习算法
- 2.6 模型评估与验证
- 2.7 Scikit-learn简介
- 2.8 机器学习常见问题







2.1 机器学习概述

2.1.1 什么是机器学习

2.1.2 机器学习的基本要素

2.1.3 机器学习的基本流程





2.1.1 什么是机器学习


1. 机器学习含义

定义

- ◆ 机器学习是一门人工智能的分支学科，它通过构建算法，让计算机能够从结构化或非结构化的训练数据中自动学习规律和模式，并利用这些习得的规律对未知数据进行预测或决策。
- ◆ 把传统机器学习理解为一个“数据 + 算法 = 模型”的过程。

(1)从学习方式维度

- ◆ 传统编程：告诉机器每一步怎么做（如果遇到A，就执行B）。
- ◆ 机器学习：给机器展示大量的例子（这些是A，对应的正确做法是B），机器自己总结出从A到B的映射规则。




2.1.1 什么是机器学习

1. 机器学习含义

(2)从研究目标维度

- ◆ 机器学习的目标是“对未知数据进行预测或决策”。
- ◆ 一个有效的机器学习模型，其价值就在于拥有强大的泛化能力，能够正确处理它从未见过的样本。
- ◆ 机器学习包括个主要阶段：
- ◆ 学习/训练阶段：模型在已知数据上寻找规律（对应归纳过程）。
- ◆ 推理/预测阶段：模型将学到的规律应用到新数据上（对应泛化过程）。




2.1.1 什么是机器学习

1. 机器学习含义

(3)从输入输出维度

传统机器学习的基本流程如下：

- ◆ 输入：历史数据（包含特征，有时也包含标签）。
- ◆ 过程：算法在数据上进行训练，构建模型。这个过程往往涉及你之前了解的特征工程，将原始数据转换成算法易于理解的形式。
- ◆ 输出：一个训练好的模型，可以用来预测新数据的标签或发现数据内在的结构。




2.1.1 什么是机器学习

2. 形象化比喻

A. 核心设定：学生与考试

- ◆ 机器学习模型 = 学生（一开始什么都不知道，需要学习）
- ◆ 数据集 = 习题集和参考答案（学习的素材）
- ◆ 学习/训练过程 = 学生做习题并对照答案（从错误中总结经验）
- ◆ 模型知识 = 解题公式或思路（从习题中总结出的规律）
- ◆ 模型预测 = 参加正式考试，解新题（应用总结出的规律）




2.1.1 什么是机器学习

2. 形象化比喻

B. 学习过程

- ◆ 第一步：准备学习资料（数据收集与准备）。
- ◆ 第二步：开始学习（模型训练）。
- ◆ 第三步：模拟考试（模型验证）。
- ◆ 第四步：正式考试（模型预测）。



2.1.1 什么是机器学习


3. 案例

【例】通过某个区域历史房子的销售信息对未来的房价进行预测。

- ◆ (1)数据：100套房子的信息
- ◆ (2)特征：面积、卧室数、地段等
- ◆ (3)标签：实际房价
- ◆ (4)目标：学习面积与房价的关系

学习过程：

- ◆ 先猜一个关系：房价 = $a \times \text{面积} + b$
- ◆ 计算预测值与真实值的差距（损失）
- ◆ 调整a和b，让差距变小
- ◆ 重复直到差距足够小
- ◆ 结果：得到适当的a和b。



2.1.2 机器学习的基本要素

1. 数据

- ◆ 数据是机器学习的“燃料”，是一切学习的基础。
- ◆ 数据的数量、质量和代表性决定了模型能否学到有效的规律。
- ◆ 数据通常由以下两部分组成：
 - ◆ 特征：描述样本的各种属性（如人的年龄、收入、购买历史）。特征的选择和质量直接影响模型的上限。
 - ◆ 标签（可选）：在监督学习中，每个样本对应一个期望的输出（如“是垃圾邮件”或“房价”）。无监督学习则没有标签。

2.1.2 机器学习的基本要素

2. 模型

- ◆ 模型是对现实问题的数学抽象，用于描述输入（特征）与输出（预测）之间的关系。
- ◆ 模型本质上是一个带有参数的函数，学习的目的就是确定这些参数的最佳取值。
- ◆ 常见模型如下：
 - ◆ 线性模型：如线性回归、逻辑回归，假设输入与输出之间存在线性关系。
 - ◆ 非线性模型：如决策树、支持向量机（带核函数）、神经网络，可以捕捉更复杂的模式。
 - ◆ 概率模型：如朴素贝叶斯，通过概率分布来描述数据。

2.1.2 机器学习的基本要素

3. 学习算法

- ◆ 学习算法是调整模型参数的具体方法和步骤。
- ◆ 学习算法定义了如何利用数据来更新模型，使得模型的预测性能不断提升。
- ◆ 学习算法的选择会影响训练速度、模型性能和收敛性。
- ◆ 常见学习算法包括：
 - ◆ 梯度下降法：通过计算损失函数关于参数的梯度，沿着梯度反方向更新参数，逐步减小误差。
 - ◆ 最小二乘法：直接求解线性回归的解析解。
 - ◆ 坐标下降法、拟牛顿法等：用于更复杂的优化问题。

2.1.2 机器学习的基本要素

4. 目标函数

- ◆ 目标函数是衡量模型预测好坏的标准，是学习的“指挥棒”。
- ◆ 目标函数量化了模型预测值与真实值之间的差距。
- ◆ 学习算法的目标就是最小化（或最大化）这个目标函数。
- ◆ 常见目标函数如下：
 - ◆ 均方误差：用于回归问题，衡量预测值与真实值之差的平方的平均值。
 - ◆ 交叉熵损失：用于分类问题，衡量预测概率分布与真实分布之间的差异。
 - ◆ 合页损失：用于支持向量机。

2.1.2 机器学习的基本要素


5. 评估指标

- ◆ 评估指标用来客观衡量训练好的模型在实际任务中的表现。
- ◆ 评估指标独立于训练过程，用于模型选择、调优和最终性能汇报。
- ◆ 评估指标必须与业务目标对齐，才能真正反映模型的价值。
- ◆ 常见的评估指标有：
 - ◆ 分类任务：准确率、精确率、召回率、F1分数、ROC-AUC等。
 - ◆ 回归任务：均方根误差、平均绝对误差、 R^2 等。
 - ◆ 聚类任务：轮廓系数、调整兰德指数等。

2.1.2 机器学习的基本要素


6. 特征工程

- ◆ 在传统机器学习中，特征工程是传统机器学习的关键，几乎是决定模型效果的核心要素之一。
- ◆ 优秀的特征工程能将领域知识融入模型，极大提升模型性能。
- ◆ 常见特征工程包括：
 - ◆ 特征提取：从原始数据中构造更有意义的特征。
 - ◆ 特征选择：从众多特征中挑选出对预测最有用的特征，降低维度，避免过拟合。
 - ◆ 特征变换：如归一化、标准化、离散化等，使数据更适合模型处理。




2.1.3 机器学习的基本流程

- ◆ **1. 问题定义与目标设定：**明确要解决的业务问题，确定机器学习任务类型（回归、分类还是降维？），确定评估指标。
- ◆ **2. 数据收集与预处理：**获取原始数据，进行清洗（处理缺失值、异常值）、标准化/归一化（将不同尺度的特征统一到相同范围）。
- ◆ **3. 特征工程：**这是传统机器学习中非常关键的一步。包括从原始数据中提取更有用的特征、构建新特征、选择最重要的特征等。特征工程的质量对最终模型效果影响很大，通常需要一定的领域知识。
- ◆ **4. 模型选择与训练：**根据任务类型（分类、回归、聚类等）选择合适的算法，用处理好的数据让模型学习，调整内部参数。



2.1.3 机器学习的基本流程


- ◆ **5. 模型评估与调优：**使用未在训练中出现过的验证集或测试集来评估模型的性能（如准确率、均方误差）。如果效果不理想，需要返回调整特征、模型参数或更换算法。
- ◆ **6. 模型部署与应用：**将训练好的模型应用到实际系统中，对新数据进行预测。



2.2 数据预处理和特征工程


2.2.1 数据预处理


2.2.2 特征工程



2.2 数据预处理和特征工程

- ◆ 原始数据通常是不完整、不一致、包含噪声的，并且其原始形式可能不适合机器学习算法直接学习。
- ◆ 数据预处理旨在将原始数据转换为干净、规范的格式。
- ◆ 特征工程则是在此基础上，通过领域知识和数学变换，创建更能体现数据内在规律的特征，从而提高模型的表达能力。
- ◆ 通常，这两部分工作占据项目总时间的60%~80%，其重要性不言而喻。





2.2.1 数据预处理

1. 数据清洗

(1) 缺失值处理

- ◆ 缺失值是数据中最常见的问题。处理方法取决于缺失机制、缺失比例以及业务背景。
- ◆ A. 直接删除
- ◆ 删除样本：当缺失值占比较小（如 $<5\%$ ）且随机出现时，可直接删除含缺失值的行。
- ◆ 删除特征：当特征缺失比例过高（如 $>50\%$ ）或该特征对任务贡献较小时，直接删除该特征。

2.2.1 数据预处理

1. 数据清洗

(1) 缺失值处理

◆ B. 统计填充

- ◆ 均值/中位数/众数填充：对于数值型特征，用均值或中位数填充；对于类别型特征，用众数填充。中位数对异常值更鲁棒。
- ◆ 条件填充：按某些分组（如按性别填充年龄）计算统计量，能更精确地还原数据分布。

◆ C. 插值法

- ◆ 线性插值：适用于时间序列等有序数据，利用前后值线性估计缺失值。
- ◆ 多项式插值/样条插值：对非线性趋势拟合更好，但需注意过拟合

2.2.1 数据预处理

1. 数据清洗


(1) 缺失值处理

◆ D. 模型预测填充

- ◆ 将缺失特征作为目标变量，用其他完整特征建立回归或分类模型进行预测。
- ◆ 这种方法能利用特征间关系，但需注意避免数据泄露（即预测时不能使用测试集信息）。

◆ E. 标记缺失

- ◆ 对于某些场景（如用户未填写某项），缺失本身可能携带信息。
- ◆ 可以新增一个二值特征（如“年龄是否缺失”），同时用常数填充原特征。



2.2.1 数据预处理

1. 数据清洗

(2) 异常值处理

- ◆ 异常值可能由测量误差、数据录入错误或真实极端事件引起。处理方法需结合业务理解。
- ◆ A. 检测方法
 - ◆ 统计方法：基于正态分布的 3σ 原则（超出均值 ± 3 倍标准差），或基于分位数的箱线图
 - ◆ 距离方法：如DBSCAN聚类、孤立森林等，可检测非全局异常。
 - ◆ 业务规则：例如年龄 > 150 或 < 0 视为异常。

2.2.1 数据预处理

1. 数据清洗


(2) 异常值处理

◆ B. 处理方法

- ◆ 删除：若异常值比例很低且确认为错误，可删除。
- ◆ 截尾处理（盖帽法）：将超出阈值的值替换为阈值（如用99%分位数替换过高的值）。
- ◆ 视为缺失：将异常值视为缺失，再用缺失值处理方法处理。
- ◆ 离散化：将连续特征分箱，异常值会被归入边界箱中。

(3) 重复值处理

- ◆ 识别并删除完全重复的样本，避免某些样本被过度加权。



2.2.1 数据预处理

2. 数据集成

- ◆ 当数据来自多个源（如数据库、CSV、API）时，需合并成一致的数据集。
- ◆ 常见数据集成方法：
 - ◆ (1) 实体识别：判断不同数据源中的记录是否代表同一实体（如用户ID的映射）。
 - ◆ (2) 冗余处理：同名特征可能含义不同（如不同表中的“销售额”可能是含税或不含税），需统一语义。
 - ◆ (3) 数据冲突：同一属性的值在不同源中不一致时，需根据可信度或时间戳选择。

2.2.1 数据预处理

3. 数据变换

(1)无量纲化（特征缩放）

- ◆ 消除特征间的量纲影响，使不同尺度的特征能在同一尺度下比较。常见方式如下。

- ◆ A.标准化（Z-score）：将数据转换为均值为0、标准差为1的分布。适用于数据分布近似正态且存在离群点的情况。具体公式如下：

$$x' = \frac{x - \mu}{\sigma}$$

- ◆ B.归一化（Min-Max Scaling）：将数据映射到[0,1]区间。对距离度量敏感（如KNN、K-Means），但易受离群点影响。具体公式如下：

$$x' = \frac{x - \min}{\max - \min}$$

2.2.1 数据预处理

3. 数据变换

(2)离散化 (分箱)

- ◆ 将连续变量划分为若干区间，转换为类别变量。有助于引入非线性，减少噪声影响。
 - ◆ 等宽分箱：将特征值域均匀划分为k个区间。
 - ◆ 等频分箱：使每个区间包含大致相等的样本数。
 - ◆ 基于聚类分箱：用K-Means等聚类算法将连续值聚为k类，用类别标签代替。
 - ◆ 二值化：将连续特征按阈值分割为0/1，适用于某些二值指标。

2.2.1 数据预处理

3. 数据变换

(3) 函数变换

- ◆ 处理长尾分布或异方差性，使数据更符合模型假设（如线性回归要求误差正态分布）。
 - ◆ 对数变换： $\log(x+c)$ 常用于右偏分布，如收入、房价。
 - ◆ Box-Cox变换：广义幂变换，自动选择最佳参数 λ ，要求数据为正。
 - ◆ Yeo-Johnson变换：Box-Cox的扩展，可处理负值。
 - ◆ 平方根、倒数变换：适用于特定场景。

(4) 数据类型转换

- ◆ 将字符串形式的日期解析为数值型时间戳（如Unix时间戳）。
- ◆ 将整数编码的类别变量显式转为category类型，便于后续编码。

2.2.1 数据预处理

案例

【例 2.1】处理缺失值——客户年龄与收入数据。

原始数据如下：

年龄	收入（千元）	性别	购买
25	50	男	是
NaN	80	女	否
30	NaN	男	是
45	120	女	是
NaN	60	男	否
35	NaN	女	否

2.2.1 数据预处理

案例

分析与处理

(1) 问题识别

年龄：客户 2 和 5 缺失年龄。

收入：客户 3 和 6 缺失收入。

(2) 处理步骤

- 分析缺失机制：判断是否为随机缺失（本例假设随机缺失）。

- 选择填充策略：

年龄：用均值或中位数填充，但考虑到性别可能影响年龄分布，采用按性别分组的中位数填充。

收入：收入通常呈偏态分布，使用中位数填充更稳健。

(3) 处理结果

客户 ID	年龄	收入（千元）	性别	购买
1	25	50	男	是
2	35*	80	女	否
3	30	70*	男	是
4	45	120	女	是
5	30*	60	男	否
6	35	70*	女	否

注：带*为填充值，年龄分组填充后，男性中位数 30，女性中位数 35；收入中位数 70。*

2.2.1 数据预处理

案例

【例 2.2】异常值检测与处理——商品价格数据。

原始数据如下：

某电商平台商品价格列表（单位：元）：

[29, 45, 38, 1200, 32, 41, 37, 55, 2100, 43, 39, 48]

分析与处理

(1) 问题识别

明显的异常值：1200 和 2100 远高于其他商品，可能是标价错误或高端商品。

(2) 处理步骤

- 检测异常值：使用箱线图的 IQR 准则。

计算 Q1（第一四分位数）和 Q3（第三四分位数）。

$$IQR = Q3 - Q1$$

$$\text{下限} = Q1 - 1.5 * IQR, \text{上限} = Q3 + 1.5 * IQR$$

- 处理策略：用上限值截尾（盖帽法），即大于上限的值替换为上限。

(3) 处理结果

下限：11.0，上限：89.0

处理前：[29 45 38 1200 32 41 37 55 2100 43 39 48]

处理后：[29 45 38 89 32 41 37 55 89 43 39 48]

2.2.1 数据预处理

案例

【例 2.3】数据变换——标准化与归一化。

原始数据如下：

假设有两个特征：年龄（20~50 岁）和年收入（3 万~100 万），数值范围差异大。

年龄：[25, 30, 35, 40, 45]

收入：[50, 80, 120, 200, 350]（单位：千元）

分析与处理

(1) 问题识别

收入和年龄量纲不同，若使用 KNN、SVM 或神经网络，需要对特征进行缩放。

(2) 处理步骤

标准化（Z-score）：将数据转换为均值为 0，标准差为 1。

归一化（Min-Max）：将数据缩放到 [0, 1] 区间。

2.2.1 数据预处理

案例

(3) 处理结果

- 标准化后:

```
[[ -1.41421356 -1.06061584]
 [-0.70710678 -0.63019153]
 [ 0.          0.02772509]
 [ 0.70710678  0.70678167]
 [ 1.41421356  1.55630061]]
```

- 归一化后:

```
[[0.  0. ]
 [0.25 0.1 ]
 [0.5  0.23333333]
 [0.75 0.5 ]
 [1.  1.  ]]
```

2.2.1 数据预处理

案例

【例 2.4】类别特征编码——服装尺码与颜色。

原始数据

服装 ID	尺码	颜色	销量
1	S	红色	120
2	M	蓝色	80
3	L	绿色	95
4	M	红色	110
5	XL	蓝色	60

分析与处理

(1) 问题识别

尺码（有序类别）和颜色（无序类别）需要转换为数值。

(2) 处理步骤

尺码：有序，可用标签编码（S→0，M→1，L→2，XL→3）。

颜色：无序，用独热编码。

(3) 处理结果

服装 ID	尺码	颜色	销量	尺码编码	颜色_红色	颜色_蓝色	颜色_绿色
1	S	红色	120	2	1	0	0
2	M	蓝色	80	1	0	1	0
3	L	绿色	95	0	0	0	1
4	M	红色	110	1	1	0	0
5	XL	蓝色	60	3	0	1	0

2.2.2 特征工程


1. 特征构建

(1) 基于业务理解

- ◆ 结合领域知识，创建有意义的复合指标。例如：
 - ◆ 金融风控：根据“借款金额”和“还款金额”构造“逾期金额”；根据“收入”和“负债”构造“负债收入比”。
 - ◆ 电商推荐：用户历史购买次数、平均消费金额、最近一次购买距今天数等。

(2) 数学变换与交叉特征

- ◆ 多项式特征：通过原始特征的乘方、乘积生成新特征（如，线性模型借此引入非线性。
- ◆ 组合特征：将多个类别特征拼接（如“城市” + “职业”），捕捉交互效应，需注意维度爆炸。




2.2.2 特征工程

1. 特征构建

(3)时间特征

- ◆ 分解：从时间戳提取年、月、日、星期几、小时、是否周末、季度、一年中的第几周等。
- ◆ 差分：计算与前一时刻的差值（时间序列）。
- ◆ 窗口统计：过去N小时/天的均值、最大值、趋势等。
- ◆ 距离特征：距离某个固定事件（如注册日、节假日）的天数。



2.2.2 特征工程

1. 特征构建

(4) 文本特征

- ◆ TF-IDF：衡量词在文档中的重要性。
- ◆ 词袋模型：统计词频。
- ◆ 词嵌入：如Word2Vec、BERT等预训练模型提取语义向量。

(5) 图像/声音特征（略）

- ◆ 通常需要专用方法（如CNN提取特征）
- ◆ 有时也需预处理（如归一化像素值）。


2.2.2 特征工程

2. 特征编码

将非数值数据（类别、文本）转换为模型可接受的数值形式。

(1) 类别特征编码

- ◆ 标签编码：将k个类别映射为0到k-1的整数。适用于有序类别（如学历：小学<中学<大学），但无序类别使用会引入虚假顺序。
- ◆ 独热编码：创建k个二进制特征，每个代表一个类别。无顺序假设，k过大会导致维度灾难。
- ◆ 计数编码：用类别在训练集中出现的次数替代原类别。适用于高频类别可能更有意义的场景。
- ◆ 频次编码：用类别出现的频率（次数/总样本数）替代。
- ◆ 目标编码：用类别对应的目标变量均值替代原类别。



2.2.2 特征工程

2. 特征编码

(2)数值特征的分箱与编码

- ◆ 对连续特征分箱后，得到的类别可用独热编码或嵌入编码。

(3)嵌入 (Embedding)

- ◆ 对于高基数类别（如用户ID、物品ID），可将其映射为低维稠密向量，在神经网络中通过嵌入层学习。


2.2.2 特征工程

3. 特征选择

从原始特征集中选出最有用于子集，降低过拟合风险，提升训练速度。

(1) 过滤式 (Filter) 。

- ◆ 基于统计指标评估每个特征与目标变量的关系，独立于模型。
 - ◆ 方差选择：移除方差小于阈值的特征。
 - ◆ 相关系数：计算特征与目标的皮尔逊相关系数（线性关系），筛选绝对值大的。
 - ◆ 卡方检验：检验类别特征与类别目标的独立性，用于分类问题。
 - ◆ 互信息：衡量特征与目标之间的任意关系（线性和非线性），适用于分类和回归。
 - ◆ 信息增益：决策树中的分裂准则，也可用于特征筛选。




2.2.2 特征工程

3. 特征选择

(2)包裹式 (Wrapper)

- ◆ 使用目标模型的表现来评估特征子集，通常计算量大但效果好。
 - ◆ 递归特征消除：反复训练模型，剔除最不重要的特征，直至达到指定数量。
 - ◆ 前向选择：从空集开始，每次加入一个使模型性能提升最大的特征。
 - ◆ 后向消除：从全集中每次删除一个最不重要的特征。
 - ◆ 遗传算法：模拟自然选择，搜索最优特征子集。



2.2.2 特征工程


3. 特征选择

(3) 嵌入式 (Embedded)

- ◆ 特征选择作为模型训练的一部分，自动完成。
- ◆ L1正则化 (Lasso)：迫使部分特征的系数为零，实现特征选择。
- ◆ 树模型特征重要性：随机森林、XGBoost、LightGBM等能输出基于分裂次数或信息增益的特征重要性评分。
- ◆ 岭回归/弹性网络：也可结合系数大小筛选。

(4) 混合方法

- ◆ 如先使用过滤式快速筛选，再用包裹式精挑细选。



2.2.2 特征工程

4. 特征降维

- ◆ 降维通过线性或非线性组合创建新特征，降低维度。
- ◆ 降维会损失原特征的可解释性。
- ◆ 常见方法：
 - ◆ 主成分分析：无监督，寻找方差最大的正交方向。适合数据压缩，但新特征难以解释。
 - ◆ 线性判别分析：有监督，寻找使类间距离最大、类内距离最小的投影方向。
 - ◆ 奇异值分解：与PCA密切相关，可用于矩阵分解。
 - ◆ t-SNE：非线性降维，常用于可视化，不适用于建模。

2.2.2 特征工程

案例

【例 2.5】基于业务理解的复合特征——金融风控中的“负债收入比”。

(1) 背景

在信贷风控中，预测用户是否会逾期。原始数据包含用户的月收入、现有贷款月供等信息。单独看收入和月供可能无法直接反映还款压力，但二者组合的“负债收入比”是关键指标。

(2) 原始数据

用户 ID	月收入	现有贷款月供 (元)	其他月负债 (元)	是否逾期
1	20000	5000	2000	0
2	8000	4000	1500	1
3	15000	3000	1000	0
4	6000	3500	1200	1

分析与处理

(1) 特征构造

总月负债 = 现有贷款月供 + 其他月负债

负债收入比 = 总月负债 / 月收入

剩余收入 = 月收入 - 总月负债

(2) 处理结果

用户 ID	月收入	月供	其他负债	逾期	总负债	负债收入比	剩余收入
1	20000	5000	2000	0	7000	0.35	13000
2	8000	4000	1500	1	5500	0.6875	2500
3	15000	3000	1000	0	4000	0.2667	11000
4	6000	3500	1200	1	4700	0.7833	1300

2.2.2 特征工程

案例

【例 2.6】时间特征提取——用户行为时间。

(1) 背景

电商平台预测用户是否会在当天购买。原始数据包含用户上次访问时间戳。

(2) 原始数据

用户 ID	上次访问时间	是否购买
1	2023-06-01 10:30:00	1
2	2023-06-01 22:15:00	0
3	2023-05-31 08:00:00	0
4	2023-06-01 14:45:00	1

分析与处理

(1) 特征构造

小时：访问的小时（0-23）

是否工作时间：9-18 点为工作时间

是否周末：周六、日

距离今日零点的分钟数：将时间映射到一天内的连续值

距离上次大促的天数（若有）


(2) 处理结果


用户 ID	访问小时	访问分钟	是否工作时间	星期几	是否周末	距离今天天数	购买
1	10	630	1	3	0	0	1
2	22	1335	0	3	0	0	0
3	8	480	0	2	0	1	0
4	14	885	1	3	0	0	1

2.3 机器学习分类

2.3.1 按学习模式分类

2.3.2 按任务类型分类





2.3.1 按学习模式分类

1. 监督学习

(1)含义

- ◆ 机器学习中最常见的一种方法，它的核心是利用带有标签的数据（即已知输入和对应的正确输出）来训练模型，以便模型能够对新的、未见过的数据做出预测。

(2)基本设定


- ◆ 给定一组输入-输出对（训练集） $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ ，学习一个函数 $f: X \rightarrow Y$ ，使得 $f(x)$ 能够对新的 x 预测出正确的 y 。

2.3.1 按学习模式分类

1. 监督学习

(3)主要算法

- ◆ A.回归算法：用于预测一个连续值的输出，比如预测房价、股票价格、销售额等。
 - ◆ 线性回归：最简单、最基础的回归算法。它假设输入特征与输出值之间存在线性关系。
 - ◆ 多项式回归：线性回归的扩展。当数据不是简单的直线关系，而是一条曲线时，使用多项式特征来拟合。
 - ◆ 岭回归与套索回归：为了防止线性回归过拟合（模型在训练集上表现太好，但在测试集上表现差），在损失函数中加入正则化项的两种算法。



2.3.1 按学习模式分类

1. 监督学习

(3)主要算法


- ◆ B.分类算法：用于预测一个离散的类别标签，比如判断肿瘤是良性还是恶性（二分类）、手写数字识别（多分类）等。
 - ◆ 逻辑回归：名字里有“回归”，但它其实是用于分类的算法。
 - ◆ K近邻：一种基于实例的学习算法，非常直观。
 - ◆ 支持向量机：一种强大的分类器，尤其在处理高维数据和小样本数据时表现出色。
 - ◆ 朴素贝叶斯：基于贝叶斯定理的分类算法，并假设特征之间相互独立（这也是“朴素”一词的由来）。

2.3.1 按学习模式分类

1. 监督学习

(3)主要算法

- ◆ B.分类算法：用于预测一个离散的类别标签，比如判断肿瘤是良性还是恶性（二分类）、手写数字识别（多分类）等。
 - ◆ 决策树：一种树形结构的模型，非常直观易懂。
 - ◆ 集成学习算法：这类算法不满足于只训练一个模型，而是训练多个弱模型（如决策树），并将它们组合起来，以获得更好的泛化性能。
 - ◆ 神经网络：受人脑神经元结构启发而设计的算法。由输入层、隐藏层和输出层组成。




2.3.1 按学习模式分类

1. 监督学习

(3) 算法选择

- ◆ 数据简单、需要可解释性强：可以优先考虑线性回归或决策树。
- ◆ 数据量大、特征复杂：随机森林或XGBoost这类集成方法通常表现更稳定。
- ◆ 文本分类：朴素贝叶斯或支持向量机通常是很好的起点。
- ◆ 高维小样本数据：支持向量机是不错的选择。



2.3.1 按学习模式分类


2. 无监督学习

(1)含义

- ◆ 与监督学习不同，无监督学习使用的数据是没有标签的。它的目标是让模型自己去发现数据内在的结构、模式或规律。

(2)基本设定

- ◆ 给定一组没有标签的数据 $\{x_1, x_2, \dots, x_n\}$ ，学习数据中的潜在规律或结构。




2.3.1 按学习模式分类

2. 无监督学习

(3)主要算法

- ◆ 根据不同的任务目标，主要分为聚类、降维和关联规则三大类。
- ◆ A.聚类算法：聚类算法的目标是将数据集中相似的样本自动归入同一个“簇”中，使得同一簇内的样本尽可能相似，不同簇之间的样本尽可能不同。
 - ◆ K均值聚类：最经典、最常用的聚类算法。
 - ◆ 层次聚类：不预先指定簇的数量，而是通过不断合并或分裂来构建一棵聚类的树状图（树状结构）。
 - ◆ DBSCAN：一种基于密度的聚类算法。它不要求簇是球形的，可以发现任意形状的簇，并且对异常值不敏感。




2.3.1 按学习模式分类

2. 无监督学习

(3)主要算法

- ◆ B.降维算法：降维是指在保留数据最主要特征的前提下，将高维数据（有很多特征）压缩成低维数据。这有助于数据可视化、减少计算复杂度以及去除噪音。
 - ◆ 主成分分析：最经典、最常用的降维算法。
 - ◆ t-SNE：一种非常流行且效果很好的非线性降维技术，特别适用于将高维数据可视化到二维或三维空间。
 - ◆ 线性判别分析：虽然也是一种降维技术，但它实际上是有监督的（需要用到标签）。在这里提及是为了与PCA对比。




2.3.1 按学习模式分类

2. 无监督学习

(3)主要算法

- ◆ C.关联规则学习：关联规则学习的目的是发现大规模数据集中变量之间的有趣关系（如“购买尿布的顾客也很可能购买啤酒”）。
 - ◆ Apriori算法：关联规则挖掘中最经典、最基础的算法。
 - ◆ FP-Growth算法：针对Apriori算法需要多次扫描数据库、效率较低的问题而提出的改进算法。
- ◆ D.异常检测：不是单独的一大类，但寻找数据中的“离群点”也是无监督学习的重要应用。
 - ◆ 孤立森林：一种专门用于异常检测的集成学习算法。




2.3.1 按学习模式分类

2. 无监督学习

(4) 算法选择

- ◆ 想给数据打标签（未知类别）：聚类（先跑K-Means，再用DBSCAN看看不规则形状）。
- ◆ 想画图看看数据长什么样（高维可视化）：先用主成分分析粗略降维，再用t-SNE 画图。
- ◆ 想挖掘"如果买了A，很可能会买B"的规律：关联规则（Apriori或FP-Growth）。
- ◆ 想从海量用户中找出"羊毛党"或骗子：异常检测（孤立森林）。



2.3.1 按学习模式分类

3. 半监督学习

(1)含义


- ◆ 半监督学习介于监督学习和无监督学习之间，利用大量未标记数据和少量标记数据来训练模型。

(2)动机

- ◆ 在实际应用中，获取标签往往成本高昂（需要人工标注）；获取无标签数据成本很低（比如网上大量的图片、文本），但给它们打上标签却很费时费力。半监督学习就是要让模型学会自己从无标签数据中挖掘信息，辅助有标签数据，从而提升学习效果。

(3)基本思想

- ◆ 利用未标记数据来辅助学习数据分布，从而改善模型性能。




2.3.1 按学习模式分类

3. 半监督学习

(4)典型方法

◆ 自训练

- ◆ 最简单、最基础的半监督学习方法，属于包装式方法。
- ◆ 先用有标签数据训练一个初始模型，然后用它对无标签数据进行预测，选出置信度高的样本，将其预测结果作为“伪标签”连同数据一起加入训练集，再重新训练模型。
- ◆ 这个过程不断迭代。这种方法简单灵活，但需注意如果初始模型不好，错误可能会被放大。




2.3.1 按学习模式分类

3. 半监督学习

(4) 典型方法

◆ 协同训练

- ◆ 这种方法假设数据可以从两个不同的角度（视图）来描述，如一个网页可以用页面文本和链接指向两个独立的视图来表示。
- ◆ 在两个视图上分别训练一个模型，然后让这两个模型互相为对方的无标签数据挑选高置信度的样本打上伪标签，并扩充到对方的训练集中。
- ◆ 该方法能利用不同视角的信息相互促进，但要求数据确实存在独立的视图，这在现实中有时难以满足。




2.3.1 按学习模式分类

3. 半监督学习

(4) 典型方法

◆ 生成式方法

- ◆ 这类方法假设所有数据（无论是否有标签）都是由某个潜在的模型“生成”出来的。
- ◆ 首先假设一个模型（如高斯混合模型），然后通过有标签数据来识别“这个簇是什么类”，并利用无标签数据来更准确地勾勒出“这个簇的形状和边界”。
- ◆ 将聚类和分类融为一体，但模型假设的正确性对结果影响很大。




2.3.1 按学习模式分类

3. 半监督学习

(5) 算法选择

- ◆ 想快速实现、不改变模型结构：先试试自训练。
- ◆ 数据有天然的多视图特征（如多模态）：协同训练是很契合的选择。
 - 。
- ◆ 数据可能符合某种分布（如高斯分布）：生成式模型值得考虑。



2.3.2 按任务类型分类

这是根据模型要解决的具体问题类型来划分。

- ◆ 1. **分类任务**：预测离散的类别标签。
 - ◆ 二分类：垃圾邮件识别（是/否）、疾病诊断（阳性/阴性）。
 - ◆ 多分类：手写数字识别（0-9）、图像识别（猫/狗/车...）。
- ◆ 2. **回归任务**：预测连续的数值。
 - ◆ 示例：预测房价、预测股票价格、预测气温。
- ◆ 3. **聚类任务**：将数据分组。
 - ◆ 示例：客户细分、社交网络社区发现、异常检测。
- ◆ 4. **降维任务**：减少数据维度。
 - ◆ 示例：数据可视化、高维数据预处理、特征压缩。