


第2章 机器学习基础




湖北大学 计算机学院
王雷春



目 录

- 2.1 机器学习概述
- 2.2 数据预处理和特征工程
- 2.3 机器学习分类
- 2.4 常用监督学习算法
- 2.5 常用无监督学习算法
- 2.6 模型评估与验证
- 2.7 Scikit-learn简介
- 2.8 机器学习常见问题






2.6 模型评估与验证

2.6.1 数据集划分方法

2.6.2 分类任务评估指标

2.6.3 回归任务评估指标






2.6.1 数据集划分方法

1. 简单划分法

- ◆ (1)标准划分：训练集(60-70%)、验证集(10-20%)、测试集(10-20%)
- ◆ (2)注意事项：
 - ◆ 测试集应只在最终评估时使用一次
 - ◆ 分类任务需分层抽样以保持类别比例
 - ◆ 时间序列数据需按时间顺序划分



2.6.1 数据集划分方法

1. 交叉验证法

- ◆ K折交叉验证：将数据均分为K份，轮流用K-1份训练，1份验证，重复K次
- ◆ 分层K折交叉验证：每折保持与完整数据集相同的类别比例
- ◆ 留一法交叉验证：K等于样本数，每次留一个样本作验证
- ◆ 时间序列交叉验证：按时间顺序滚动划分，确保训练集在测试集之前

2.6.2.分类任务评估指标

1. 基于混淆矩阵的基础指标

混淆矩阵：

- ◆ TP（真阳性）：实际为正，预测为正。
- ◆ TN（真阴性）：实际为负，预测为负。
- ◆ FP（假阳性）：实际为负，预测为正（误报）。
- ◆ FN（假阴性）：实际为正，预测为负（漏报）。

(1)准确率

- ◆ 定义：预测正确的样本数占总样本数的比例。
- ◆ 公式：
$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$
- ◆ 适用场景：当各类别样本数量均衡时使用。

2.6.2.分类任务评估指标

1. 基于混淆矩阵的基础指标

(2)精确率

- ◆ 定义： 在所有被模型预测为“正”的样本中，有多少是真正的“正”。
- ◆ 公式： $\text{Precision} = \frac{TP}{TP+FP}$
- ◆ 关注点： 模型预测的“准不准”。
- ◆ 适用场景：“假阳性”成本高（如垃圾邮件过滤，把正常邮件误判为垃圾邮件会很糟糕）。

2.6.2.分类任务评估指标

1. 基于混淆矩阵的基础指标

(3)召回率

- ◆ 定义： 在所有真正的“正”样本中，有多少被模型成功找出来了。
- ◆ 公式： $\text{Recall} = \frac{TP}{TP+FN}$
- ◆ 关注点： 模型找的“全不全”。
- ◆ 适用场景： “假阴性”成本高（如疾病筛查、金融欺诈检测，漏掉坏人的后果更严重）。

(4)F1 分数

- ◆ 定义： 精确率和召回率的调和平均数，用于综合评估两者。
- ◆ 公式： $F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$
- ◆ 适用场景： 当你需要在精确率和召回率之间取得平衡，或者数据类别不平衡时，F1通常比准确率更有参考价值。

2.6.2.分类任务评估指标

2. 基于概率输出的指标

(1)ROC 曲线

◆ 定义：以假阳性率（FPR）为横轴，真正率（TPR，即召回率）为纵轴绘制的曲线。通过调整分类阈值，可以得到不同的点连成曲线。

◆ $TPR = Recall$

◆ $FPR = \frac{FP}{FP+TN}$

(2)AUC 值

◆ 定义：ROC 曲线下的面积。

◆ 范围：[0.5, 1]。AUC 值越大，模型的排序能力越强（即正样本得分普遍高于负样本）。

◆ 特点：AUC 是阈值无关的，它评估的是模型整体好坏，不依赖于具体选择的分类阈值。常用于模型对比。

2.6.2.分类任务评估指标

2. 基于概率输出的指标

(3)PR 曲线

- ◆ 定义：以召回率为横轴，精确率为纵轴的曲线。
- ◆ 适用场景：当类别极度不平衡（如广告点击率预测，点击样本极少），或者你更关心正样本的预测效果时，PR曲线比ROC曲线更能反映模型性能。

2.6.2.分类任务评估指标

3. 评估指标选择

场景	首选指标	辅助指标
类别平衡，错误代价相当	准确率	混淆矩阵
类别不平衡，误报代价高（如欺诈检测）	精确率	AUC-ROC，PR曲线
类别不平衡，漏报代价高（如疾病检测）	召回率	AUC-ROC，PR曲线
需要单一综合指标比较模型	F1-score	AUC
评估模型排序能力，不确定阈值	AUC-ROC	Log-Loss
极端不平衡（负类远多于正类）	AUC-PR	召回率 @ 特定精确率
多分类，各类别同等重要	宏观F1	混淆矩阵
多分类，样本量差异大	微观F1 / 加权F1	混淆矩阵

2.6.2.分类任务评估指标

案例

【例】分类任务评估——精确率、召回率、F1、ROC-AUC。

- ◆ (1)背景
- ◆ 假设我们训练了一个逻辑回归模型，用于预测客户是否会逾期（二分类）。测试集有1000个样本，其中真实逾期客户200个，非逾期800个。模型预测结果如下混淆矩阵。
- ◆ (2)混淆矩阵
- ◆

	预测为正（逾期）	预测为负（非逾期）
真实为正（逾期）	150 (TP)	50 (FN)
真实为负（非逾期）	100 (FP)	700 (TN)

2.6.2.分类任务评估指标

案例


- ◆ **【例】分类任务评估——精确率、召回率、F1、ROC-AUC。**
- ◆ (3)计算各项指标
- ◆ 准确率 = $(TP + TN) / \text{总样本} = (150+700)/1000 = 0.85$
- ◆ 精确率 = $TP / (TP + FP) = 150 / (150+100) = 0.60$
- ◆ 召回率 = $TP / (TP + FN) = 150 / (150+50) = 0.75$
- ◆ F1分数 = $2 * (\text{精确率} * \text{召回率}) / (\text{精确率} + \text{召回率}) = 2 * (0.6*0.75)/(0.6+0.75) \approx 0.667$
- ◆ 特异度 = $TN / (TN + FP) = 700 / (700+100) = 0.875$
- ◆ (4)ROC曲线与AUC
- ◆ 假设模型输出概率，我们可以绘制ROC曲线（真正率 vs 假正率）并计算AUC（曲线下面积）。AUC越接近1越好。

2.6.2.分类任务评估指标

案例

运行结果:

- ◆ 准确率: 0.85
- ◆ 精确率: 0.6
- ◆ 召回率: 0.75
- ◆ F1分数: 0.6666666666666666
- ◆ AUC: 0.96875



2.6.3.回归任务评估指标

1. 评估指标

(1)平均绝对误差

- ◆ 定义：预测值与真实值之间绝对差值的平均值。
- ◆ 公式： $MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$
- ◆ 特点：直观易懂，与原始数据单位一致，对异常值（极端大或小的误差）的惩罚相对较小。
- ◆ 适用场景：当你想了解预测值与真实值的平均差距，且不希望异常值过度影响评估结果时。

2.6.3.回归任务评估指标

1. 评估指标

(2)均方误差

- ◆ 定义：预测值与真实值之间差值的平方的平均值。
- ◆ 特点：对大误差非常敏感（因为平方放大了大误差的影响），是很多回归优化算法的默认损失函数。
- ◆ 公式： $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$
- ◆ 缺点：量纲是原始单位的平方，可解释性较差。
- ◆ 适用场景：当大误差需要被特别惩罚时（如金融风险预测，一个大的偏差可能导致严重后果）。

2.6.3.回归任务评估指标

1. 评估指标

(3)均方根误差

- ◆ 定义：均方误差的平方根，将误差单位恢复到原始量纲。
- ◆ 公式：
$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$
- ◆ 特点：兼具 MSE 对大误差敏感的特性，同时量纲与原始数据一致，更易解释。
- ◆ 注意：如果数据中存在异常值，RMSE 会比 MAE 受到更大的影响。
- ◆ 适用场景：需要误差单位与原始数据相同，且希望突出大误差时。

2.6.3.回归任务评估指标

1. 评估指标

(4)决定系数 R^2

- ◆ 定义：模型解释的变异占总变异的比例，或者说相比简单使用均值作为预测，模型减少了多少误差。
- ◆ 公式：
$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$
- ◆ 范围：通常 $[0,1]$ ，但若模型预测效果极差（比简单均值还差）， R^2 可能为负。
- ◆ 解释： $R^2 = 0.8$ 意味着模型可以解释80%的目标变量方差。
- ◆ 注意：当增加无关特征时， R^2 不会降低（甚至可能轻微上升），因此它不能用于惩罚模型复杂度。

2.6.3.回归任务评估指标

2. 回归任务指标选择

场景	首选指标	辅助/备选	说明
异常值较多，希望模型稳健	MAE	Huber损失	避免异常值主导模型
大误差不可接受，需要严格惩罚	RMSE 或 MSE	R^2	放大较大误差的影响
业务需要理解误差的实际大小	RMSE / MAE	两者同时报告	比较差值可了解误差分布
评估相对误差，比较不同量纲数据	MAPE / SMAPE	相对绝对误差	适用于非零正值场景
模型解释或特征选择	调整 R^2	R^2	考虑特征数量惩罚
自定义业务代价（如缺货 > 积压）	分位数损失	加权MAE	对高估/低估不对称惩罚

2.6.3.回归任务评估指标

案例

【例】回归任务评估——MSE、MAE、 R^2 。

◆ (1)背景

◆ 预测房价，真实房价和预测房价如下（5个样本）：

◆ 样本 真实房价（万元） 预测房价（万元）


◆ 1	200	190
◆ 2	280	270
◆ 3	350	360
◆ 4	180	200
◆ 5	300	290

2.6.3.回归任务评估指标

案例

【例】回归任务评估——MSE、MAE、 R^2 。

- ◆ (2)计算指标
- ◆ 均方误差 = $((200-190)^2 + (280-270)^2 + (350-360)^2 + (180-200)^2 + (300-290)^2) / 5 = (100 + 100 + 100 + 400 + 100)/5 = 160$
- ◆ 均方根误差 = $\sqrt{160} \approx 12.65$
- ◆ 平均绝对误差 = $(|10| + |10| + |10| + |20| + |10|)/5 = 60/5 = 12$
- ◆ $R^2 = 1 - (\text{残差平方和} / \text{总平方和})$
- ◆ 残差平方和 = $160 \times 5 = 800$
- ◆ 总平方和 = $(200-262)^2 + (280-262)^2 + (350-262)^2 + (180-262)^2 + (300-262)^2$ (均值262) = $(62^2 + 18^2 + 88^2 + (-82)^2 + 38^2) = 3844 + 324 + 7744 + 6724 + 1444 = 20080$
- ◆ $R^2 = 1 - 800/20080 \approx 0.96$




2.6.3.回归任务评估指标

案例

运行结果:

- ◆ MSE: 160.0
- ◆ RMSE: 12.649110640673518
- ◆ MAE: 12.0
- ◆ R^2 : 0.9601593625498008



2.7 Scikit-learn简介


2.7.1 什么是 Scikit-learn

2.7.2 数据集及使用方法

2.7.3 常用模块及调用


2.7.4 机器学习案例





2.7.1 什么是 Scikit-learn


- ◆ Scikit-learn (简称 sklearn) 是一个基于 Python 编程语言的、开源、免费、功能强大、易于上手的机器学习库。
- ◆ Scikit-learn 基于 NumPy、SciPy 和 Matplotlib 构建，以其简洁一致的API设计、全面的算法覆盖、卓越的性能表现和出色的文档质量，成为机器学习领域的标准工具库。
- ◆ Scikit-learn是学习机器学习原理和实践应用的理想选择。



2.7.1 什么是 Scikit-learn

核心特点:


- ◆ 功能全面且覆盖完整流程。Scikit-learn 不仅仅是算法的集合，它几乎涵盖了机器学习项目的全流程。
- ◆ API 设计极其统一和简洁。无论是数据预处理、模型训练还是预测，都遵循统一的“三步走”接口，学习成本极低。
- ◆ 强大的 Pipeline 与集成能力。为了确保流程的可重现性并防止数据泄露，Scikit-learn 引入了 Pipeline（管道）机制。它可以将“数据标准化” -> “特征降维” -> “模型训练”等一系列步骤封装为一个整体工作流，让代码更整洁、更健壮。



2.7.1 什么是 Scikit-learn

核心特点:

- ◆ 开源与社区生态。Scikit-learn 采用宽松的 BSD 许可证，可免费用于商业和研究。它拥有非常庞大且活跃的社区，官方文档详尽且示例丰富，是新手入门和开发者快速解决问题的首选参考。



2.7.2 常见数据集及使用方法


常见数据集：

◆ A.监督学习数据集：

- ◆ 分类任务：如鸢尾花数据集 (iris)、手写数字图像数据集 (digits)、葡萄酒化学成分数据集 (wine) 等。
- ◆ 回归任务：如糖尿病进展数据集 (diabetes)、加州房价数据集和体能训练数据集 (linnerud, 多元回归) 等。

◆ B.无监督学习数据集：


- ◆ 聚类任务：如葡萄酒化学成分数据集 (wine)、威斯康星州乳腺癌数据集 (breast_cancer) 等。
- ◆ 降维任务：如Olivetti Faces 人脸数据集、20 Newsgroups 文本数据集等。



2.7.2 常见数据集及使用方法

数据集使用方法：

- ◆ 以Iris 鸢尾花数据集为例，其调用方法如下：
 - ◆ `from sklearn.datasets import load_iris`
 - ◆ `iris = load_iris()`
 - ◆ `X = iris.data` # 特征矩阵
 - ◆ `y = iris.target` # 真实标签（仅用于验证）



2.7.3 常用模块及调用


1. 数据准备与预处理模块

(1)sklearn.model_selection - 数据集划分

- ◆ train_test_split函数：最常用的数据分割工具，可按指定比例随机划分数据集，并可选保持类别比例平衡。
- ◆ 使用方法：指定特征矩阵、目标向量、测试集比例和随机种子，返回四个数据集：训练特征、测试特征、训练标签、测试标签。

(2)sklearn.preprocessing - 数据标准化与编码

- ◆ A.数值特征处理：
- ◆ StandardScaler类：标准化处理器，将数据转换为均值为0、标准差为1的分布。调用时先创建对象，用训练数据拟合参数，然后分别转换训练和测试数据。




2.7.3 常用模块及调用

1. 数据准备与预处理模块

- ◆ MinMaxScaler类：归一化处理器，将数据缩放到指定范围（默认0到1）。使用方式与标准化类似。
- ◆ B.类别特征处理：
- ◆ OneHotEncoder类：独热编码器，将分类变量转换为二进制向量。每个类别对应一个二进制特征列。
- ◆ LabelEncoder类：标签编码器，将类别标签转换为整数编码。注意：通常只用于目标变量编码。

(3)sklearn.impute - 缺失值处理

- ◆ SimpleImputer类：简单填充器，提供均值、中位数、众数或常数填充策略。先拟合训练数据计算填充值，再转换所有数据。



2.7.3 常用模块及调用


2. 特征工程模块

(1)sklearn.feature_selection - 特征选择

- ◆ SelectKBest类：基于统计检验选择K个最佳特征。需要指定评分函数（如卡方检验）和特征数量。
- ◆ RFE类：递归特征消除，通过反复构建模型并移除最弱特征来选择特征子集。需要指定基础估计器和要选择的特征数。

(2)sklearn.decomposition - 降维

- ◆ PCA类：主成分分析，将高维数据投影到低维空间，保留主要方差。可以指定降维后的维度数或保留的方差比例。



2.7.3 常用模块及调用


3. 监督学习算法模块

(1)sklearn.linear_model - 线性模型

- ◆ LinearRegression类：普通最小二乘线性回归，拟合线性关系。
- ◆ LogisticRegression类：逻辑回归，用于二分类或多分类问题，输出概率值。
- ◆ Ridge和Lasso类：正则化回归，分别使用L2和L1惩罚项防止过拟合。

(2)sklearn.ensemble - 集成学习

- ◆ RandomForestClassifier/Regressor类：随机森林，通过构建多棵决策树并集成结果，具有良好泛化能力。
- ◆ GradientBoostingClassifier/Regressor类：梯度提升树，通过串行构建决策树来纠正前序树的错误。
- ◆ VotingClassifier类：投票集成，组合多个不同分类器的预测结果。



2.7.3 常用模块及调用


3. 监督学习算法模块

(3)sklearn.svm - 支持向量机

- ◆ SVC类：支持向量分类器，可处理线性和非线性分类问题，通过核函数映射到高维空间。
- ◆ SVR类：支持向量回归器，用于回归问题。

(4)sklearn.tree - 决策树

- ◆ DecisionTreeClassifier/Regressor类：决策树模型，提供良好的可解释性，可控制树的最大深度等参数防止过拟合。



2.7.3 常用模块及调用

4. 无监督学习算法模块

(1)sklearn.cluster - 聚类算法

- ◆ KMeans类：K均值聚类，基于距离将数据划分为K个簇，需要预先指定簇数量。
- ◆ DBSCAN类：基于密度的聚类，可以发现任意形状的簇，并能识别噪声点。

2.7.3 常用模块及调用

5. 模型评估与选择模块

(1) sklearn.metrics - 评估指标

◆ A. 分类任务：

- ◆ accuracy_score函数：计算分类准确率，正确预测的比例。
- ◆ precision_score、recall_score、f1_score函数：计算精确率、召回率和F1分数，用于不平衡分类评估。
- ◆ confusion_matrix函数：生成混淆矩阵，展示分类结果详细情况。
- ◆ classification_report函数：生成分类报告，包含多个评估指标的汇总。

◆ B. 回归任务：


- ◆ mean_squared_error函数：计算均方误差，衡量预测值与真实值差异。
- ◆ r2_score函数：计算决定系数，表示模型解释的方差比例。

2.7.3 常用模块及调用

5. 模型评估与选择模块

(2)sklearn.model_selection - 模型选择与验证

- ◆ cross_val_score函数：执行K折交叉验证，返回每折的评分，更稳健地评估模型性能。
- ◆ GridSearchCV类：网格搜索超参数调优，穷举指定的参数组合，通过交叉验证选择最佳参数。
- ◆ RandomizedSearchCV类：随机搜索超参数调优，从参数分布中采样，适合参数空间较大的情况。



2.7.3 常用模块及调用

6. 管道与 workflow 模块

(1) sklearn.pipeline - 构建机器学习流水线

- ◆ Pipeline类：将多个数据处理和建模步骤封装为单一估计器。按顺序执行每个步骤，前一步骤的输出作为下一步骤的输入。简化了工作流程，防止了数据泄露。

(2) sklearn.compose - 列变换器

- ◆ ColumnTransformer类：对不同列应用不同的预处理转换。特别适用于同时包含数值和类别特征的数据集。

2.7.3 常用模块及调用

7. 数据加载模块

(1) sklearn.datasets - 内置数据集


- ◆ load_*函数：加载经典数据集，如鸢尾花、波士顿房价、手写数字等。
 - 。
- ◆ make_*函数：生成模拟数据集，用于算法测试和演示。

2.7.3 常用模块及调用

8. 通用调用模式

(1)估计器的标准工作流程

- ◆ 所有Scikit-learn估计器都遵循统一的调用模式：
- ◆ A.初始化：创建模型或处理器对象，可设置相关参数。
- ◆ B.拟合：调用fit方法，传入训练数据和目标值（对于监督学习），让模型学习数据特征。
- ◆ C.转换/预测：
- ◆ 对于转换器：调用transform方法，对新数据进行相同处理。
- ◆ 对于预测器：调用predict方法，对新数据进行预测。
- ◆ D.评估：对于预测器，可调用score方法快速评估模型性能。



2.7.3 常用模块及调用

8. 通用调用模式

(2)数据预处理的特殊模式


- ◆ 对于需要从训练数据学习参数的预处理步骤（如标准化、编码），必须：
- ◆ A.仅使用训练数据拟合转换器。
- ◆ B.使用拟合好的转换器同时转换训练数据和测试数据。
- ◆ C.绝对避免使用测试数据拟合转换器，否则会导致数据泄露。

2.7.3 常用模块及调用

8. 通用调用模式

(3)管道的工作方式

- ◆ 管道将多个步骤组合为单一对象：
- ◆ A.按顺序定义处理步骤列表，每个步骤是一个（名称，估计器）元组。
- ◆ B.对整个管道调用fit方法时，会按顺序对每个步骤调用fit和transform（最后一步只调用fit）。
- ◆ C.预测时，数据会依次通过所有步骤（最后一步调用predict）。



2.7.3 常用模块及调用

8. 通用调用模式

(4)模型评估的最佳实践

- ◆ A.始终使用独立的测试集评估最终模型性能。
- ◆ B.使用交叉验证进行模型选择和超参数调优。
- ◆ C.根据问题类型选择合适的评估指标。
- ◆ D.对于分类问题，特别是类别不平衡时，不要仅依赖准确率。

2.7.3 常用模块及调用

案例


【例】鸢尾花 (Iris) 品种分类。使用经典的鸢尾花数据集，通过多种机器学习算法构建分类模型，预测鸢尾花的三个品种 (Setosa、Versicolour、Virginica)。要求比较不同算法的性能，并通过可视化展示分类效果。

◆ 具体要求：

◆ (1)数据：使用Scikit-learn内置的load_iris()数据集，包含150个样本，每个样本有4个特征（花萼长度、花萼宽度、花瓣长度、花瓣宽度），标签为3种鸢尾花品种。

◆ (2)模型：至少实现三种不同的分类算法，例如：

- ◆ 逻辑回归 (Logistic Regression)
- ◆ 决策树 (Decision Tree)
- ◆ 支持向量机 (SVM)



2.7.3 常用模块及调用

案例

【例】鸢尾花 (Iris) 品种分类。使用经典的鸢尾花数据集，通过多种机器学习算法构建分类模型，预测鸢尾花的三个品种 (Setosa、Versicolour、Virginica)。要求比较不同算法的性能，并通过可视化展示分类效果。

- ◆ (3)评估：使用准确率 (Accuracy) 作为主要评估指标，并输出分类报告 (精确率、召回率、F1-score) 。
- ◆ (4)可视化：
 - ◆ 绘制数据集中两两特征之间的散点图矩阵，观察不同品种的分布。
 - ◆ 选取两个最具区分度的特征，绘制不同分类器的决策边界对比图。
- ◆ (5)调参：对至少一个模型进行简单的超参数调优 (例如使用网格搜索 GridSearchCV) 。

2.7.3 常用模块及调用

案例

实现分析：


- ◆ (1)数据集简介
- ◆ 鸢尾花数据集是机器学习领域最著名的多分类数据集之一。它包含3个类别，每个类别50个样本。四个特征均为连续数值，单位是厘米。数据没有缺失值，且特征之间具有一定的相关性（例如花瓣长度和花瓣宽度高度相关）。由于类别均衡，准确率是一个合适的评估指标。
- ◆ (2)探索性分析
- ◆ 通过散点图矩阵可以发现：
- ◆ Setosa品种（蓝色）在花瓣长度和花瓣宽度上明显区别于其他两类，线性可分。
- ◆ Versicolour和Virginica在特征空间中有部分重叠，但总体上仍可区分，可能需要非线性模型或复杂边界。

2.7.3 常用模块及调用

案例

实现分析：

- ◆ (3)建模思路
- ◆ A.数据预处理：由于特征尺度不同（花萼长度范围较大，花瓣宽度范围较小），对特征进行标准化（StandardScaler）有助于提升SVM和逻辑回归等对尺度敏感的模型的性能。
- ◆ B.数据集划分：按照7:3的比例划分训练集和测试集，保持类别比例（分层抽样）。
- ◆ C.模型选择：
- ◆ 逻辑回归：线性模型，适合线性可分问题。通过多分类（一对多或多项分布）实现。
- ◆ 决策树：非线性模型，可生成直观的规则，容易过拟合，需控制树深度



2.7.3 常用模块及调用

案例

实现分析：


- ◆ 支持向量机（SVM）：可选用RBF核处理非线性边界，对尺度敏感，需要标准化。
- ◆ D.评估与对比：计算各模型在测试集上的准确率，并输出详细的分类报告，分析每个类别的精确率和召回率。
- ◆ E.调参优化：以SVM为例，使用网格搜索寻找最优的C和gamma参数，提高泛化能力。
- ◆ (4)决策边界可视化
- ◆ 选择花瓣长度和花瓣宽度这两个最具区分度的特征（通过观察散点图或特征重要性），在二维平面上绘制不同模型的决策区域，直观感受分类器的学习能力。

2.7.3 常用模块及调用

案例

运行结果:

- ◆ 特征名称: ['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal width (cm)']
- ◆ 类别名称: ['setosa' 'versicolor' 'virginica']
- ◆ 数据形状: (150, 4)



2.7.3 常用模块及调用

案例

运行结果:

◆ === Logistic Regression ===

◆ 测试集准确率: 0.9111

◆ 分类报告:

◆		precision	recall	f1-score	support
◆	setosa	1.00	1.00	1.00	15
◆	versicolor	0.82	0.93	0.88	15
◆	virginica	0.92	0.80	0.86	15
◆	accuracy			0.91	45
◆	macro avg	0.92	0.91	0.91	45
◆	weighted avg	0.92	0.91	0.91	45

2.7.3 常用模块及调用

案例

运行结果:

◆ === Decision Tree ===

◆ 测试集准确率: 0.9778

◆ 分类报告:

◆	precision	recall	f1-score	support
◆ setosa	1.00	1.00	1.00	15
◆ versicolor	0.94	1.00	0.97	15
◆ virginica	1.00	0.93	0.97	15
◆ accuracy			0.98	45
◆ macro avg	0.98	0.98	0.98	45
◆ weighted avg	0.98	0.98	0.98	45

2.7.3 常用模块及调用

案例


运行结果:

◆ === SVM (RBF) ===

◆ 测试集准确率: 0.9333

◆ 分类报告:

◆	precision	recall	f1-score	support
◆ setosa	1.00	1.00	1.00	15
◆ versicolor	0.88	0.93	0.90	15
◆ virginica	0.93	0.87	0.90	15
◆ accuracy			0.93	45
◆ macro avg	0.93	0.93	0.93	45
◆ weighted avg	0.93	0.93	0.93	45



2.7.3 常用模块及调用




案例

运行结果:

- ◆ === SVM Grid Search Results ===
- ◆ 最佳参数: {'C': 1, 'gamma': 0.1}
- ◆ 最佳交叉验证准确率: 0.9810
- ◆ 测试集准确率: 0.9111

2.7.3 常用模块及调用

案例




2.7.3 常用模块及调用

案例

运行结果与分析


- ◆ (1)散点图：展示花瓣长度与花瓣宽度的分布，清晰显示Setosa与其他两类分离，Versicolour和Virginica有重叠但总体可分。
- ◆ (2)各模型的准确率和分类报告：
- ◆ 逻辑回归和SVM通常能达到很高的准确率（约0.98-1.0），因为数据在标准化后线性部分可分。
- ◆ 决策树（限制深度为3）可能略低，但依然有不错的表现。
- ◆ (3)网格搜索结果：SVM的最佳参数（如 $C=1$, $\gamma=0.1$ ）可进一步提升泛化能力。
- ◆ (4)决策边界图：对比三种模型在二维特征空间中的分类区域。SVM和逻辑回归的边界较为平滑，决策树呈现分段常数区域。



2.8 机器学习特点及局限性

1. 特点


- ◆ 可解释性强：模型结构相对简单（如决策树、线性回归），容易理解特征与输出的关系，适合金融、医疗等需要解释的领域。
- ◆ 数据需求较小：在小样本（几十到几千）场景下表现稳定，不依赖海量数据和GPU算力。
- ◆ 训练效率高：计算复杂度低，在普通CPU上即可快速训练和推理。
- ◆ 特征工程依赖：需要人工设计特征，利用领域知识可提高性能，但也增加了人力成本。



2.8 机器学习特点及局限性

1. 特点

- ◆ 理论基础扎实：基于统计学习理论（VC维、偏差-方差分解等），泛化界有较清晰的数学刻画。
- ◆ 模型多样性强：包含回归、分类、聚类、降维等多种任务的方法，覆盖广泛的应用场景。



2.8 机器学习特点及局限性

2. 局限性

- ◆ 处理高维原始数据能力弱：对图像、语音、文本等高维原始数据直接建模困难，依赖手工特征提取，难以自动学习层次化表示。
- ◆ 非线性拟合能力有限：线性模型、树模型虽然可以处理部分非线性，面对复杂函数（如深度网络能拟合的函数）往往力不从心。
- ◆ 扩展性差：在大规模数据（百万级样本、万级特征）上，传统算法（如SVM、核方法）计算复杂度过高，难以扩展。
- ◆ 特征工程成本高：需要大量人工尝试和领域知识，且特征设计往往与任务强绑定，泛化到新任务时需要重新设计。